

面向遮挡物操作的阶段条件语义预测与图像空间视觉伺服

从自动语义标注到可验证闭环控制的中文方法草稿

作者待定

2026 年 8 月 11 日

摘要

动作分块 Transformer (ACT) 能够从示范中学习复杂操作，但长动作块在执行期间可能因视觉误差、接触扰动和执行器滞后而逐渐过时。本文提出一个精简的闭环框架：首先利用人工审核过的稀疏提示、SAM2 和轻量级 YOLO 提示生成器自动构建语义标注，并对自动标签进行离线质量评估；随后从任意数量的相机视角提取面积、质心、距离和接触等可解释语义状态；利用带顺序约束的时序模型自动学习任务阶段；以 ACT 生成名义动作块，以动作条件语义动力学预测动作结果，并通过图像空间视觉伺服对名义动作进行小幅闭环修正。该方法不强制要求相机标定：单视角或多视角均可在各自归一化图像坐标中工作；只有需要将多个视角融合到统一物理坐标、报告实际距离或声明物理空间控制保证时才需要相机标定。本文给出方法成立所需的可检查条件，并将结论限定为已验证运行域内的局部可靠性，而非任意初态和任意遮挡下的全局成功保证。

关键词：自动语义标注；动作分块 Transformer；阶段学习；语义预测；无标定视觉伺服；不确定性评估

1 问题与核心思路

任务由机器人状态 $\mathbf{q}_t \in \mathbb{R}^{n_q}$ 、可用相机集合 $\mathcal{V}_t$ 和动作 $\mathbf{a}_t$ 描述。相机数量不固定： $|\mathcal{V}_t| = 1$ 时为单视角， $|\mathcal{V}_t| > 1$ 时为多视角；某个相机暂时失效时，只要仍有可靠视角，系统可以继续工作。

本文保留四个核心模块：

1. 自动生成语义标注，并在训练前评估每帧、每类标签质量；
2. 从一个或多个视角构造可解释语义状态，并自动学习任务阶段；
3. ACT 预测名义动作，语义动力学预测这些动作将产生的视觉结果；
4. 图像空间视觉伺服根据实际语义反馈修正 ACT，并在观测不可靠时缩短执行或重新规划。

该框架的目的不是用手工控制器替代 ACT。ACT 负责复杂的双臂协同和接触先验，语义闭环只负责发现动作块已经过时并做受限修正。

2 自动语义标注与标签不确定性

2.1 从少量人工审核到完整数据集

语义类别包括遮挡物或布料、目标物体、目标区域和工具/执行器，分别记为 C, O, G, A 。完整标注按照以下流程生成：

1. 使用 Codex 为少量代表视频生成初始离散 JSON。每条记录包含视频、帧号、类别和包围盒，可直接作为分割提示；
2. 将 JSON 渲染为带包围盒和类别名称的图片，由人工审核并修正错误框。人工审核的是少量关键提示，而不是逐帧描绘 mask；
3. 将审核后的框输入 SAM2，在少量种子视频中传播得到完整时序语义 mask [1]；
4. 使用这些完整种子标注训练轻量级 YOLO 网络 [2]，使其为其余视频自动生成类别框提示；
5. 将 YOLO 提示再次交给 SAM2 传播，生成整个训练数据集的逐帧语义标注。

这个流程显著减少人工成本，但最终标签仍是自动生成的。Codex 初始框、YOLO 框和 SAM2 时序传播中的任一环节都可能产生系统误差，因此标签在进入策略训练前必须经过质量门。

2.2 离线标签质量评估

对视角 v 、类别 c 和二值标签 $M_{t,c}^v$ ，记录以下原始诊断量：

时间一致性

$$q_{iou,t}^{v,c} = \frac{1}{2} [\text{IoU}(M_{t-1,c}^v, M_{t,c}^v) + \text{IoU}(M_{t,c}^v, M_{t+1,c}^v)]. \quad (1)$$

面积突变 令 $r_{t,c}^v = |M_{t,c}^v|/|\Omega_v|$ ，定义

$$d_{area,t}^{v,c} = \left| \log \frac{r_{t,c}^v + \epsilon}{r_{t-1,c}^v + \epsilon} \right|. \quad (2)$$

质心跳变 将质心坐标除以图像宽高，得到归一化质心 $\mathbf{p}_{t,c}^v \in [0, 1]^2$ ，定义

$$d_{center,t}^{v,c} = \frac{\|\mathbf{p}_{t,c}^v - \mathbf{p}_{t-1,c}^v\|}{\sqrt{2}}. \quad (3)$$

连通域异常 统计去除极小噪声区域后的有效连通域数量 $n_{cc,t}^{v,c}$ 。布料可能被机械臂遮挡而自然分裂，工具也可能包含多个部件，因此面积、运动和连通域阈值必须按“视角-类别”设置，不能所有类别、所有相机共用一个阈值。例如本任务中侧视图的工具容易与背景遮挡布混淆，而正视图受此影响较小，二者必须分别校准。

将各指标归一化为 $[0, 1]$ 的子分数后，计算

$$Q_{t,c}^v = \frac{\sum_k w_k q_{t,c,k}^v}{\sum_k w_k}, \quad Q_{t,c}^v \in [0, 1]. \quad (4)$$

单次低 IoU 可能来自真实快速运动，不能直接等同于标签错误。系统保留所有原始指标供人工抽查，并使用在独立审核集上校准的综合分数产生有效标记

$$\gamma_{t,c}^v = \mathbb{I}[Q_{t,c}^v \geq \tau_c]. \quad (5)$$

训练时，低质量类别不参与当前分割损失；未来任一必要标签不可靠时，相应时间点不参与语义动力学损失。

离线标签质量与部署时模型置信度是两个不同问题。前者回答“训练标签是否可信”，后者回答“策略当前看到的分割是否可信”，二者需要分别评估。

3 可变视角语义状态

3.1 每个视角的图像空间状态

分割模型输出软概率 $P_{t,c}^v(x, y) \in [0, 1]$ 。每个视角独立计算：

- 各类面积比例 $r_{t,c}^v$ ；
- 物体、目标区域和执行器的归一化软质心；
- 物体到目标、执行器到物体的归一化图像距离；
- 物体-目标和物体-布料的图像接触指标；
- 分割熵、时间跳变和类别可见性等在线置信度。

当前语义图采用互斥多类 softmax，所以物体和目标区域的硬标签不会在同一像素直接重叠。第一版使用局部膨胀后的接触代理

$$\eta_{OG,t}^v = \frac{\sum_{x,y} P_{t,O}^v(x, y) \mathcal{D}_\rho(P_{t,G}^v)(x, y)}{\sum_{x,y} P_{t,O}^v(x, y) + \epsilon}, \quad (6)$$

其中 $\mathcal{D}_\rho$ 是局部软膨胀。它表示图像邻接或占据程度，不等于真实三维物理重叠。

将上述量组成视角状态 $\mathbf{z}_t^v$ 。全部量都在各自图像坐标内归一化，因此不需要知道相机内参、外参或桌面单应矩阵。

3.2 单视角与多视角统一处理

对每个可靠视角使用共享编码器 ϕ ，再进行与视角数量无关的集合聚合：

$$\mathbf{h}_t = \rho \left(\frac{\sum_{v \in \mathcal{V}_t} \alpha_t^v \phi(\mathbf{g}_t^v \odot \mathbf{z}_t^v, \mathbf{g}_t^v, e_v)}{\sum_{v \in \mathcal{V}_t} \alpha_t^v + \epsilon} \right), \quad (7)$$

其中 $\mathbf{g}_t^v \in [0, 1]^{d_z}$ 是按语义类别和特征计算的置信门， α_t^v 是该视角对当前任务相关特征的总体可用度， e_v 是可学习的视角标识。这样可以只降低侧视图 tool 特征的权重，同时保留侧视图 object 和 region 的信息，而不是丢弃整个侧视角。一个视角时公式自然退化为单视角；多个视角时，不

同相机提供遮挡互补信息。训练时随机丢弃视角和单个类别特征，使模型学会在观测缺失时退化运行。

未经标定时，不直接平均不同相机中的质心坐标，而是先分别编码再聚合。若任务需要厘米级距离、统一桌面轨迹或把多个视角严格融合到同一物理坐标，则需要相机内外参或桌面单应标定。这是物理坐标融合的条件，不是图像空间视觉伺服的必要条件。

4 自动阶段学习

4.1 阶段定义

任务阶段记为

$$\mathcal{M} = \{U, E, T, R, D\}, \quad (8)$$

分别表示掀开遮挡物、暴露并分离目标、运输目标、恢复遮挡物和完成。

单帧语义标签不能唯一决定阶段。例如开始和完成时都可能看到较大布料面积。因此阶段模型必须使用最近 L 帧的语义状态、机器人状态和动作历史：

$$\pi_t^m = p_\psi(m_t \mid \mathbf{h}_{t-L+1:t}, \mathbf{q}_{t-L+1:t}, \mathbf{a}_{t-L:t-1}). \quad (9)$$

4.2 不逐条人工标边界的学习方法

五阶段可以主要通过学习获得，不必人工校正每条轨迹。训练流程为：

1. 根据高质量语义序列自动产生软事件候选：物体持续可见、物体与布料持续分离、物体持续进入目标区域、布料恢复且动作趋于停止；
2. 将事件候选转换为带置信度的软阶段标签，而不是立即生成不可修改的硬标签；
3. 使用只允许 $U \rightarrow E \rightarrow T \rightarrow R \rightarrow D$ 前向转移的 HMM、GRU 或 Transformer 学习阶段；
4. 对低置信、阶段逆序、事件缺失和模型分歧大的轨迹进行人工抽查；
5. 用审核过的小子集校准阈值和阶段概率，再重新生成全部阶段标签。

完全无人工锚点也可以聚类出若干时序状态，但不能保证“第 2 类”在语义上一定对应运输阶段，这属于阶段置换和可辨识性问题。因此合理目标是“自动标注全部轨迹，只审核少量困难轨迹”，而不是“完全取消任何人工验证”。

部署时对阶段概率使用连续帧投票、滞回和最小驻留时间，防止一次分割抖动造成阶段来回切换。

5 语义预测 ACT 与无标定视觉伺服

5.1 ACT 名义动作

ACT 根据 RGB、软语义图、机器人状态和阶段表示预测长度为 H 的名义动作块 [3]:

$$\mathbf{a}_{t:t+H-1}^{ACT} = \pi_{ACT}(I_t, \mathbf{h}_t, \mathbf{q}_t, \boldsymbol{\pi}_t^m). \quad (10)$$

ACT 保留复杂示范行为, 策略以较短间隔重新观察和规划, 而不是盲目执行完整长动作块。

5.2 动作条件语义动力学

学习模型预测给定动作后的未来语义状态及不确定性:

$$p_{\theta}(\mathbf{h}_{t+k} | \mathbf{h}_t, \mathbf{q}_t, \mathbf{a}_{t:t+k-1}, \boldsymbol{\pi}_t^m), \quad k \in \mathcal{K}. \quad (11)$$

预测均值用于判断视觉进度, 预测方差和独立校准残差共同构成可信区间。训练 softmax 自信并不代表动力学误差有界, 因此误差界必须在未参与训练的轨迹上校准。

5.3 图像空间视觉目标

每个阶段定义简单、可解释的图像目标:

$$V_U = [r_C - \bar{r}_U]_+^2 + \lambda_{Uv} [\bar{r}_O - r_O]_+^2, \quad (12)$$

$$V_E = \lambda_{Ec} [\eta_{OC} - \bar{\eta}_{OC}]_+^2, \quad (13)$$

$$V_T = [d_{OG} - \bar{d}_T]_+^2 + \lambda_{T\eta} [\bar{\eta}_T - \eta_{OG}]_+^2, \quad (14)$$

$$V_R = \lambda_{Rc} [\bar{r}_R - r_C]_+^2 + \lambda_{R\eta} [\bar{\eta}_D - \eta_{OG}]_+^2, \quad (15)$$

$$V_D = 0. \quad (16)$$

单视角时直接使用该视角的 V_m^v ; 多视角时按可靠度加权, 或对关键误差采用保守最大值。阈值由成功训练轨迹和独立校准轨迹确定, 不能在最终测试集上反复调整。

5.4 为什么不一定需要相机标定

经典基于图像的视觉伺服可以直接让图像误差下降 [4]。本文不把像素速度直接解释为三维末端速度, 而是从示范数据学习局部关系

$$\Delta \mathbf{h}_t = \mathbf{f}_m(\mathbf{h}_t) + \mathbf{G}_m(\mathbf{h}_t) \Delta \mathbf{a}_t + \mathbf{d}_t, \quad (17)$$

其中 $\Delta \mathbf{a}_t$ 是关节目标增量。只要局部模型 $\mathbf{G}_m$ 在当前运行域内准确, 便可以在图像空间判断某个关节修正是否使 V_m 下降, 不需要显式相机标定。这属于学习型、无标定图像视觉伺服。

相机标定在以下情况才是必要或明显有益的:

- 要把不同视角的点融合成统一三维点或桌面坐标;

- 要直接使用解析图像雅可比矩阵，而不是学习局部动作-图像关系；
- 要报告厘米、毫米等物理尺度误差；
- 要把碰撞距离、工作空间边界等物理安全约束写入控制器。

5.5 受限闭环修正

令 ACT 当前动作增量为 $\Delta \mathbf{a}_t^{ACT}$ 。在局部模型上寻找距离 ACT 最近的修正：

$$\Delta \mathbf{a}_t^*, \delta_t^* = \arg \min_{\Delta \mathbf{a}, \delta \geq 0} \frac{1}{2} \|\Delta \mathbf{a} - \Delta \mathbf{a}_t^{ACT}\|_W^2 + p_\delta \delta^2 \quad (18)$$

$$\text{s.t. } \widehat{\Delta V_m}(\mathbf{h}_t, \Delta \mathbf{a}) + \beta_{model} + \beta_{obs} \leq -\rho_m V_m(\mathbf{h}_t) + \delta, \quad (19)$$

$$\Delta \mathbf{a}_{min} \leq \Delta \mathbf{a} \leq \Delta \mathbf{a}_{max}. \quad (20)$$

这里 β_{model} 和 β_{obs} 分别上界动力学预测误差和观测误差。QP 只做满足视觉下降条件所需的最小修正；若松弛 δ 过大或观测不可靠，则不继续声称下降，而是停止、减速或立即重新规划。

6 训练目标与执行流程

总损失保留四项：

$$\mathcal{L} = \mathcal{L}_{ACT} + \lambda_{seg} \mathcal{L}_{seg}^{quality} + \lambda_{phase} \mathcal{L}_{phase} + \lambda_{dyn} \mathcal{L}_{dyn}^{quality}. \quad (21)$$

其中分割和动力学损失仅在质量标记 $\gamma = 1$ 的标签上计算。阶段损失使用软伪标签与少量审核标签；动力学损失预测未来语义分布，而非生成完整 RGB。

推荐按以下顺序训练：

1. 完成自动语义标注、离线质量评估和小规模人工校准；
2. 训练分割与 ACT 基线，并验证单视角和多视角输入；
3. 自动生成阶段软标签，训练时序阶段模型并审核困难轨迹；
4. 使用专家动作训练语义动力学，在独立校准集上估计误差界；
5. 先以影子模式记录 QP 修正，不发送给机器人；验证后再逐步开放小幅修正。

在线控制循环为：获取可用视角、预测语义和置信度、更新阶段、ACT 预测动作块、语义模型预测未来、QP 计算首个受限修正、执行少量动作，然后重新观察。若视角置信度过低、阶段异常变化、实际语义超出预测区间或 V_m 未按预期下降，则提前重新规划。

7 方法成立的条件

7.1 局部可靠性结论

在阶段 m 的已验证运行域 $\mathcal{D}_m$ 内，假设真实离散视觉变化与学习模型的误差对 V_m 的影响不超过 $\beta_{model} + \beta_{obs}$ 。若 QP 可行并满足上述鲁棒下降约束，则实际闭环满足

$$V_m(\mathbf{h}_{t+1}) - V_m(\mathbf{h}_t) \leq -\rho_m V_m(\mathbf{h}_t) + \delta_t. \quad (22)$$

当 $\delta_t \leq \bar{\delta}_m$ 时， V_m 收敛到大小与 $\bar{\delta}_m/\rho_m$ 有关的邻域。该结论是局部、条件性的：它只在观测可信、模型误差界有效且 QP 可行时成立。

7.2 条件是否能够达到

条件	如何检查或实现	可达到性
自动标签质量可控	人工审核独立小样本，校准各类质量分数，屏蔽低质量帧	可以，但不能零人工
至少一个视角可观测	训练视角丢弃，部署时使用置信门并允许降级运行	通常可以
阶段可辨识	使用时间历史、顺序约束、软标签和困难轨迹审核	可以近似达到
局部动作-视觉模型准确	划分独立校准集，检查预测区间覆盖率和域外检测	局部可以
视觉目标在动作限制内可控	离线检查 QP 可行率，实机影子测试，限制修正幅度	需实验验证
延迟和执行长度有界	短间隔重规划，记录端到端延迟，异常时中断	工程上可以
测试状态接近训练域	扩充初始位置、遮挡和恢复数据，并进行域外检测	只能部分满足

表 1: 可靠性条件、检查方法与现实可达到性。

这些条件在受控工作台、固定任务对象和覆盖充分的数据中是可以近似达到并实证检查的，但很难在任意新物体、任意相机位置、完全遮挡或严重缠绕下始终成立。因此合理表述是“在校准运行域内提高闭环可靠性并满足局部视觉下降条件”，而不是“保证所有任务必然成功”。

8 实验环境与验证方案

建议首先在受控桌面操作环境中验证：机器人、任务对象和工作区域保持一致，使用一个或多个固定 RGB 相机，控制频率、图像延迟和动作执行间隔均可记录。相机可以有不同分辨率和观察方向，但训练阶段必须覆盖部署时可能出现的相机组合；若相机移动、镜头更换或视野明显改变，应视为新的运行域并重新校准质量阈值和动力学误差界。当前已知侧视图的 tool 会受到背景遮挡布干扰，因此实验必须单独报告 front-tool 与 side-tool 的标签质量、在线置信度和消融结果。

数据按完整轨迹划分为训练集、校准集和测试集，不能把同一轨迹的相邻帧分到不同集合。训练集用于分割、阶段模型、ACT 和语义动力学训练；校准集用于确定标签质量阈值、阶段置信阈值、预测区间和 QP 裕量；测试集只用于最终报告。为了验证单视角与多视角能力，应分别报告单个相机、全部相机、随机缺失相机和短时遮挡四种设置。

评估至少包含四组指标：自动标签在人工审核子集上的类别 IoU/Dice 与质量分校准误差；四个事件边界的平均帧误差、阶段准确率和低置信轨迹召回率；动作条件语义预测误差及预测区间覆盖率；实机任务成功率、重规划次数、QP 可行率和视觉误差实际下降比例。只有当这些指标在独立测试轨迹上稳定，且部署环境未明显超出训练与校准范围时，才认为前述局部可靠性条件近似成立。

9 简单说明

整个方法可以理解为：先用少量人工审核教会自动标注系统“画对语义 mask”，再给每张自动标签打质量分；策略只相信高质量标签。机器人运行时，ACT 先给出它根据示范学到的一段动作，语义预测模型判断这段动作大概会把物体和布料带到哪里。执行少量动作后，系统重新看图像：如果物体确实更接近目标，就继续；如果没有进展、阶段判断改变或视觉不可信，就缩短执行并重新规划。视觉伺服只在图像坐标中要求“误差变小”，所以单相机可以工作，多相机只是提供更多互补证据，并不天然要求相机标定。

10 局限性

1. 自动质量指标只能发现时间跳变、面积异常、质心异常和拓扑异常，无法识别长期稳定但始终分错类别的系统偏差，因此仍需人工审核独立子集；
2. 单视角完全遮挡时没有方法能从当前图像恢复真实状态，多视角只能降低而不能消除这个问题；当前侧视图 tool 与背景遮挡布的混淆属于已知的视角相关偏差，必须单独校准和降权；
3. 无标定图像伺服只保证图像指标下降，不能直接解释为三维距离、碰撞距离或末端位姿误差下降；
4. 接触代理来自互斥语义图的局部邻接，不是真实物理接触。更精确的判断需要 amodal 标注、深度或标定后的目标区域；
5. 成功示范主要覆盖正常轨迹。卡住、推过目标、物体丢失和恢复行为需要额外失败/接管数据；
6. 阶段伪标签可能继承语义错误。顺序约束能减少抖动，但不能修复系统性误标；
7. 学习动力学和误差界只在校准域内有效。相机位置、光照、物体外观或机器人延迟显著变化后必须重新验证。

11 结论

本文给出一个从自动语义数据到闭环策略的精简方案。方法以 Codex、人工审核、SAM2 和轻量 YOLO 构成低成本标注流水线，以离线质量门避免自动标签被无条件信任；以可变视角语义状态和时序模型自动学习任务阶段；以 ACT 保留复杂示范行为，以语义动力学和图像空间视觉伺服提供短周期反馈修正。相机标定不是图像空间闭环的必要条件，但在跨视角物理融合和物理安全约束中仍然必要。方法能够提供的是已验证运行域内、误差界成立时的局部可靠性，而不是不受条件限制的全局任务保证。

参考文献

- [1] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman R”adle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [2] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 779–788, 2016.
- [3] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bi-manual manipulation with low-cost hardware. In *Robotics: Science and Systems*, 2023.
- [4] François Chaumette and Seth Hutchinson. Visual servo control. I. basic approaches. *IEEE Robotics & Automation Magazine*, 13(4):82–90, 2006.