

面向双臂遮挡操作的语义进展表示与历史条件动作块修正

I. 引言

II. 相关工作

III. 问题定义与条件性理论分析

A. 任务、观测与分析范围

考虑双臂暴露、分离、目标运输与遮挡物恢复任务。令环境隐状态为 x_t ，可用相机图像与机器人关节观测为 $o_t = (\{I_t^v\}_{v \in \mathcal{V}}, q_t)$ 。环境按

$$x_{t+1} = f(x_t, u_t, \xi_t), \quad o_t = h(x_t, \nu_t) \quad (1)$$

演化，其中接触、形变和遮挡使得 o_t 通常不足以唯一确定 x_t 。该表达只定义问题，不假设已知 f, h ，也不使用它们进行控制计算。暴露等阶段可由任务谓词描述，但全局进展不必是单调标量；目标重遮挡、接触失败等情况可能产生局部倒退。本文不把三个图像几何量定义为完整隐状态。

慢策略在观测索引 k 输出长度 K 的基础动作块 $B^{(k)} = (b_{k,0}, \dots, b_{k,K-1})$ 。快分支在 $t \geq k$ 观察后，为目标时刻 $\tau = t + d + j$, $j = 0, \dots, H-1$ 预测残差。目标动作索引、计划身份及观察时刻均是模型条件，而不是事后对齐的自由变量。以下推导固定一个目标槽位，块级结论通过在有效槽位上求期望得到。

设 $D = \text{diag}(\sigma_1, \dots, \sigma_{n_a})$ ，其中 $\sigma_j > 0$ 仅由训练动作统计确定。分析在标准差缩放的动作空间进行， $Y = D^{-1}a_\tau^{\text{demo}}$ 、 $B = D^{-1}b_\tau^{(k)}$ 。不减动作均值，因为残差为差值。 Y 是示范指令，不宣称等于唯一最优控制。

假设 1 (固定分布与因果性): 对一个固定的评价分布 μ ，以下涉及的动作、几何、标签噪声和预测均具有有限二阶矩。各模型训练完成后参数固定；或等价地，所有期望条件于训练集。模型在观察时刻只能使用当时可得图像、关节、已发送动作和已生效计划，不得使用未来专家动作、未来图像或尚未完成的新计划。

本节主要研究平方动作风险

$$\mathcal{R}_\mu(\pi) = \mathbb{E}_\mu \|Y - \pi\|^2. \quad (2)$$

它允许给出精确分解，但不等于后文使用的 Smooth L1 训练损失，也不等于实机成功率。不同策略诱导的闭环状态分布通常不同；固定 μ 下的改进不能直接推广至所有闭环轨迹。条件期望的正交投影性质是下述风险分析的基础 [1]。

B. 语义表示不创造观测信息

设固定分割器产生 $S = g_\psi(I)$ 。令 X 包含当前 RGB 及需要的其余观测。由于 S 对 X 可测，有

$$\sigma(X, S) = \sigma(X), \quad \mathbb{E}[Y | X, S] = \mathbb{E}[Y | X]. \quad (3)$$

当互信息有限时，亦有 $I(Y; X, S) = I(Y; X)$ ，符合数据处理不等式 [2]。因此不能声称同帧分割增加了理想观察者的信息量，或消除了完全遮挡引起的不可辨识性。

语义分支的作用在于将额外标签中学到的先验带入有限样本策略训练。其潜在收益是学习任务相关表示的归纳偏置，而不是无条件信息增益。预训练知识固定后，式(3)仍成立。

C. 几何可读出误差与动作风险的条件性联系

令 $\mathcal{O}$ 为指定时刻允许使用的完整观测集合， $m(\mathcal{O}) = \mathbb{E}[Y | \mathcal{O}]$ 。令 G 为从可靠语义定义出的任务相关几何， C 为关节、目标时间和其他控制条件。不假设 G 单独足以决定动作。

假设 2 (近似任务相关性与局部平滑性): 存在函数 f_G ，使得

$$\mathbb{E} \|m(\mathcal{O}) - f_G(G, C)\|^2 \leq \epsilon_{\text{suf}}, \quad (4)$$

且在所分析的任务域内，对几何输入满足一致的 Lipschitz 条件

$$\|f_G(g, C) - f_G(g', C)\| \leq L_G \|g - g'\|. \quad (5)$$

令 Z 为策略表示，几何预测为 $\hat{G} = d_\omega(Z)$ ， $\mathbb{E} \|\hat{G} - G\|^2 \leq \epsilon_G$ 。对实际动作读出 $\hat{\pi}$ ，还需要

$$\mathbb{E} \|\hat{\pi} - f_G(\hat{G}, C)\|^2 \leq \epsilon_{\text{read}}. \quad (6)$$

式(6)明确要求动作分支确实使用与几何一致的信息；仅训练辅助头不自动满足它。接触模式切换附近可能不存在小的统一 L_G ，因此分析应局限于适用的任务域，或分模式进行。

命题 1 (几何表示的风险上界): 在假设1-2下，若 $\hat{\pi}$ 对 $\mathcal{O}$ 可测，则

$$\mathcal{R}_\mu(\hat{\pi}) - \mathcal{R}_\mu(m) \leq 3\epsilon_{\text{suf}} + 3L_G^2\epsilon_G + 3\epsilon_{\text{read}}. \quad (7)$$

证明: 条件期望正交性给出 $\mathcal{R}_\mu(\hat{\pi}) - \mathcal{R}_\mu(m) = \mathbb{E} \|\hat{\pi} - m\|^2$ 。将括号内差值分解为 $\hat{\pi} - f_G(\hat{G}, C)$ 、 $f_G(\hat{G}, C) - f_G(G, C)$ 、 $f_G(G, C) - m$ 三项，使用 $\|a+b+c\|^2 \leq 3(\|a\|^2 + \|b\|^2 + \|c\|^2)$ 及 Lipschitz 条件即得。■

此界说明需要同时控制几何误差、几何不充分性和动作读出误差，而不是只降低辅助 loss。它不是语义优于 RGB 的比较定理；两个方法上界的大小不同，也不能据此比较实际风险。本实现的 ACT 直接读取全部 encoder 特征，未硬编码为 $f_G(\hat{G}, C)$ ，故 ϵ_{read} 必须通过机制分析约束，不能删除。

若训练几何标签为 $\tilde{G} = G + \eta$ ，则

$$\mathbb{E} \|\hat{G} - G\|^2 \leq 2\mathbb{E} \|\hat{G} - \tilde{G}\|^2 + 2\mathbb{E} \|\eta\|^2. \quad (8)$$

由此可见，拟合伪标签的误差小，并不保证对真实几何误差小。标签质量需要独立审核，不能仅用网络对同一伪标签的一致性证实。

D. 几何与进展判定：有间隔才可稳健

某一进展事件若确实可由 $p(G) = \mathbf{1}\{\phi(G) \geq 0\}$ 表示，且 ϕ 为 L_ϕ -Lipschitz，则对任意 $\gamma > 0$ ，

$$\mathbb{P}\{p(\hat{G}) \neq p(G)\} \leq \mathbb{P}\{|\phi(G)| \leq \gamma\} + \frac{L_\phi^2 \epsilon_G}{\gamma^2}. \quad (9)$$

证明：在 $|\phi(G)| > \gamma$ 的集合上，错误翻转要求 $L_\phi \|\hat{G} - G\| > \gamma$ ，再用 Markov 不等式并加上边界集合概率。该式将事件边界模糊性和几何估计误差分开。

但不是任意进展事件都满足这个表示条件。目标质心进入区域，不等于整个目标都进入区域；面积为零也无法区分从未暴露和重新遮挡。若事件依赖历史，可将 G 扩展为相应历史关系，代价是重新检验误差与间隔条件。式(9)不把当前三个 query 自动提升为完整阶段/完成判定器。

E. 质量加权何时可靠，何时产生选择偏差

设 V 为辅助预测输入， $W \in [0, 1]$ 为标签质量与有效性权重，并在 $\mathbb{E}[W | V] > 0$ 的支持集考虑平方损失。对 $\tilde{G}$ 的加权总体最优预测为

$$f_W(V) = \frac{\mathbb{E}[W\tilde{G} | V]}{\mathbb{E}[W | V]}. \quad (10)$$

由条件加权二次函数求导可得。与真实条件均值的差为

$$f_W(V) - \mathbb{E}[G | V] = \frac{\text{Cov}(W, G | V)}{\mathbb{E}[W | V]} + \frac{\mathbb{E}[W\eta | V]}{\mathbb{E}[W | V]}. \quad (11)$$

向量协方差按分量定义。加权噪声条件均值为零且权重不改变真实条件均值时，式(11)为零；否则门控可能偏向容易、静止或可见样本，改变学习目标。

这里给出的是偏差条件，不宣称满足条件就不加权有更低有限样本方差。当前 SAM2 质量分数是启发式诊断，未被证明为逆噪声方差或正确概率；实际组归一化 Smooth L1 也不等同于式(10)。该分析用于明确质量加权需要验证的条件，而非为任意权重提供保证。

F. 历史信息的价值与 GRU 压缩的代价

固定同一目标动作 Y 。令 $\mathcal{F}$ 包含当前观察、基础计划和目标索引， $\mathcal{G}$ 在此基础上加入因果历史，因此 $\mathcal{F} \subseteq \mathcal{G}$ 。定义 $m_{\mathcal{F}} = \mathbb{E}[Y | \mathcal{F}]$ 、 $m_{\mathcal{G}} = \mathbb{E}[Y | \mathcal{G}]$ 。

命题 2 (历史的最优风险收益)：在假设1下，

$$\mathcal{R}_\mu(m_{\mathcal{F}}) - \mathcal{R}_\mu(m_{\mathcal{G}}) = \mathbb{E}\|m_{\mathcal{G}} - m_{\mathcal{F}}\|^2 =: \Delta_{\text{hist}} \geq 0. \quad (12)$$

严格改进当且仅当两个条件均值以正概率不同。

证明：展开 $Y - m_{\mathcal{F}} = (Y - m_{\mathcal{G}}) + (m_{\mathcal{G}} - m_{\mathcal{F}})$ 。后项对 $\mathcal{G}$ 可测，前项条件于 $\mathcal{G}$ 的均值为零，交叉项期望消失。

对两个隐藏模式的简单例子，若给定同一当前观察，模式等概率，对应示范均值为 y_1, y_2 ，且历史完全辨别模式，则 $\Delta_{\text{hist}} = \|y_1 - y_2\|^2/4$ 。这说明在观测混叠下，当前观察策略存在不可避免的均值预测损失；不说明每个任务必有这样的模式，也不说明均值动作是安全动作。

GRU 是对历史的压缩，并非完整历史本身。设实际保留的信息 $\mathcal{T} = \sigma(C_t, Z_t^{\text{GRU}}) \subseteq \mathcal{G}$ ， $m_{\mathcal{T}} = \mathbb{E}[Y | \mathcal{T}]$ 。不要求 $\mathcal{F} \subseteq \mathcal{T}$ ，因 GRU 可能连当前信息也压缩损失。对可测预测器 $\hat{\pi}_{\mathcal{T}}$ ，定义

$$\begin{aligned} \epsilon_{\text{comp}} &= \mathbb{E}\|m_{\mathcal{G}} - m_{\mathcal{T}}\|^2, \\ \epsilon_{\text{fit}} &= \mathbb{E}\|\hat{\pi}_{\mathcal{T}} - m_{\mathcal{T}}\|^2. \end{aligned} \quad (13)$$

两次正交分解给出精确关系

$$\mathcal{R}_\mu(\hat{\pi}_{\mathcal{T}}) - \mathcal{R}_\mu(m_{\mathcal{F}}) = \epsilon_{\text{comp}} + \epsilon_{\text{fit}} - \Delta_{\text{hist}}. \quad (14)$$

因此 GRU 预测优于理想当前观察预测的充分且必要条件是 $\epsilon_{\text{comp}} + \epsilon_{\text{fit}} < \Delta_{\text{hist}}$ 。这是信息与误差条件，不是 GRU 架构优于 LSTM/Transformer 的结论。有限样本、短历史、错误记忆或观测冗余均可能使条件不满足。

G. 实时残差的精确改进条件

令 $e = Y - B$ ，残差可用信息为 U ，其中包含基础动作和相同目标索引。对任意平方可积残差 $r(U)$ ，展开平方得

$$\mathcal{R}_\mu(B) - \mathcal{R}_\mu(B + r) = 2\mathbb{E}\langle e, r \rangle - \mathbb{E}\|r\|^2. \quad (15)$$

故方向相关性必须足以抵消幅度代价，错误或过大的修正会增加风险。

令 $m_e(U) = \mathbb{E}[e | U]$ ，再次使用正交性有

$$\mathcal{R}_\mu(B) - \mathcal{R}_\mu(B + r) = \mathbb{E}\|m_e\|^2 - \mathbb{E}\|r - m_e\|^2. \quad (16)$$

无约束的最优残差为 m_e ；严格改善需要可预测误差能量大于残差逼近误差。历史或新观察的作用是改变可预测的条件误差，但同时也可能增加估计难度。

命题 3 (有界最优残差)：设 $\mathcal{C} = \{r : |r_j| \leq \beta_j\}$ ， $\beta_j > 0$ 。在总体平方风险上，最佳有界残差为 $r_{\mathcal{C}}(U) = \Pi_{\mathcal{C}}(m_e(U))$ 。其风险不高于零残差；若 m_e 以正概率非零，则严格低于零残差。

证明：给定 U 后，目标为与 r 无关的条件方差加 $\|m_e - r\|^2$ ，故最优解是欧氏投影。因 $0 \in \mathcal{C}$ ，投影不比零差；盒内含零的邻域，当 $m_e \neq 0$ 时可沿其方向取足够小的非零步得到严格改善。

零残差属于模型类，因此其他损失下的总体最优值也不劣于基础策略，但这只是可行集包含关系。零初始化、经验风险下降或使用 tanh 不保证实际学到投影解，更不保证在新分布下优于基础策略。

H. 推理延迟与重叠预测的覆盖条件

控制周期为 $\Delta > 0$ ， s, H 为正整数， d 为非负整数。观察时刻为 $t_n = t_0 + ns\Delta$ ，端到端结果可用延迟为 ℓ_n 。一轮目标槽位为

$$\mathcal{J}_n = \{t_n + (d + j)\Delta : j = 0, \dots, H - 1\}. \quad (17)$$

采用明确约定：结果在某控制槽截止时刻或之前可用才允许该槽使用。同一基础计划内，不考虑额外有效性拒绝时，过期前缀数为

$$k_n = \min\{H, \max(0, \lceil \ell_n / \Delta \rceil - d)\}. \quad (18)$$

这是把目标槽位与结果完成时间比较的直接结果，不得将第一个迟到残差平移到下一动作来改变式(18)。

命题 4 (及时覆盖与重叠容错)：若计划身份不变、观察同步、结果通过有效性检查、所有轮次 $\ell_n \leq d\Delta$ ，则从首个修正槽开始连续覆盖当且仅当 $H \geq s$ 。在前一轮全部目标有效时，当前轮跳过前缀 k_n 后仍能与前轮无缝衔接的条件为 $s + k_n \leq H$ ，并要求 $k_n < H$ 。

证明：前轮最后槽为 $t_n + (d + H - 1)\Delta$ ，下轮首个有效槽为 $t_n + (s + d + k_{n+1})\Delta$ 。后者不晚于前者的下一槽当且仅当 $s + k_{n+1} \leq H$ 。及时情形 $k_{n+1} = 0$ 即得首项。

该容错结论只针对相邻轮次，不保证连续丢帧后仍覆盖，也不跨计划继承残差。若缓存还受最大年龄 T_r 限制，

要完整保留本轮预测需 $T_r \geq (d + H - 1)\Delta$ ；历史断流阈值也必须大于正常观察间隔。计算调度、相机传输和机器人通信均计入 ℓ_n ，不能用模型平均耗时替代。

I. 从离线动作风险到闭环任务结果的边界

以上性质均不依赖学习到的接触动力学，但因此也不提供收敛定理。若额外假设两条轨迹在同一噪声耦合下满足

$$\|x_{t+1} - x'_{t+1}\| \leq L_x \|x_t - x'_t\| + L_u \|u_t - u'_t\|, \quad (19)$$

则递推可得

$$\|x_T - x'_T\| \leq L_x^T \|x_0 - x'_0\| + L_u \sum_{i=0}^{T-1} L_x^{T-1-i} \|u_i - u'_i\|. \quad (20)$$

但离线平均动作风险下降不提供每条闭环轨迹的右侧上界；接触切换还可能破坏适用的 Lipschitz 假设。要从此推至任务成功，尚需在策略访问状态上控制误差，并证明成功集合具有足够裕量。本工作不使用上述附加假设宣称稳定性或成功保证。

J. 分析的可检验结论

理论分析指出四类应独立检验的条件：几何可读出与动作利用之间的联系；历史辨识收益与压缩损失的平衡；残差方向、幅度与基础误差的关系；端到端延迟是否满足目标时间预算。质量权重还需检查其选择偏差。这些是条件性机制解释，标准投影与不等式不是本文声称新发现的数学定理。条件成立程度及实机结果留待实验部分报告，不用假设替代证据。

IV. 方法

A. 分阶段构建与信息流

系统依次构建语义标签、轻量分割器、基础语义策略和历史残差模块。各阶段的监督来源与可训练参数分开管理；不是同时端到端优化全部模块。动作块策略采用 ACT [3]。执行期修正与已有动作块修正研究共享问题背景 [4]，本文不将一般的残差相加或慢快结构本身定义为独有机制。

训练时，自动标签用于分割学习和几何监督；推理时仅使用新 RGB、关节及策略执行记录。离线双向传播使用未来视频，不会直接作为在线输入。全流程应保留独立测试 episode，避免标签模型、基础策略和残差模型的不同划分被混称为全系统未见数据泛化。

B. 自主提示与质量驱动标签迭代

首先依据类别说明和代表性视频帧生成离散 JSON 框/点提示，渲染后进行少量人工审核。对小目标暴露、接触、再遮挡等边界补充正点、相邻类负点和经审核的可见区间。SAM2 [5] 以提示传播标签；保存正反两个方向结果与合成语义图，每个像素只标当前可见表面，不能将接触的目标与工具合为同一类。

每帧每类计算邻帧 IoU 较小值 T 、相邻面积 $\log$ 变化最大值 A 、归一化质心位移最大值 C 、有效连通域数 N 、双向 IoU B 。以各类诊断阈值归一化，有

$$\begin{aligned} s_T &= \text{clip}(T/\tau_T, 0, 1), \\ s_A &= \text{clip}(1 - A/\tau_A, 0, 1), \\ s_C &= \text{clip}(1 - C/\tau_C, 0, 1), \\ s_N &= \text{clip}(N_{\max}/\max(N, 1), 0, 1), \\ s_B &= \text{clip}(B/\tau_B, 0, 1), \\ q &= (s_T + s_A + s_C + s_N + s_B)/5. \end{aligned} \quad (21)$$

双向数据缺失时，当前实现设 $s_B = 1$ ，另存可用性标志；不得将缺失视为实际测得一致。预期可见却无 mask、碎裂、低双向一致性等异常独立保存，不能被高均分覆盖。

门控输出接受、自动重试或人工复核。当前默认接受分数 0.75、低分阈值 0.55、接受双向 IoU 0.8；仅有时序/面积变化且双向 IoU 至少 0.9、无结构异常时，可保护真实转场。问题帧合并成带上下文片段，增加锚点后重跑，默认两次自动重试后仍失败才转人工。阈值是诊断设置，不是式(11)所要求的无偏性证明。

通过审核/门控的 mask 转为检测框，训练分视角 YOLO 提示器，再扩展到更多视频。若一帧真实存在的正类未通过，不将其作为遗漏该类别的检测训练样本。每轮保留提示、权重、评分和人工 override，最后验证视频对齐、mask 互斥与数据加载。这里减少的是额外语义标注成本，不是取消示范采集和人工审核。

C. 冻结 U-Net 与共享视觉编码

使用离线标签分别训练 front 和 side 轻量 TinyUNet。当前 front 含背景共 7 类：背景、遮挡物、目标、区域、工具、左右臂；side 含背景共 5 类，不单独标注机械臂。共享类别具有相同语义颜色。两个分割器以完整视野 RGB 缩放到 480×270 并使用 ImageNet 归一化。分割训练采用类别加权交叉熵及可配置前景 Dice，实际权重由模型配置固定。该独立训练器不因此自动具有逐帧质量加权通路。

将冻结分割器输出的 logits 转为概率 $P_t^v = \text{softmax}(l_t^v)$ ，再按固定调色板 $c_k \in [0, 1]^3$ 生成

$$S_t^v(u) = \sum_k P_t^v(k, u) c_k. \quad (22)$$

它保留颜色混合，不先做 argmax；多通道到 3 通道的压缩不可保证可逆。原 RGB 与语义 RGB 分别经共享 ResNet18 及投影，得到独立 token 序列。双视角共有四路视觉输入，不在像素或特征层预先相加。

当前版本不加 camera/modality embedding，使用 ACT 原位编码。U-Net 在策略学习期间冻结；动作或几何 loss 不更新它。没有显式三维配准、遮挡补全或动作监督微调分割模块。

D. 几何监督的语义 Query Token

增加三个可学习初始向量 $e_i \in \mathbb{R}^{512}$ ，与 latent、关节及视觉 token 共同输入 ACT encoder，得到当前观察相关的隐藏特征 z_i 。它们是 encoder 自注意力参与者，不是固定的几何数值输入。三个线性头 $d_i(z_i)$ 的输出维度分别为 1、1、2；动作 decoder 同时读取包含这些 token 的完整 encoder 上下文。

几何监督只从 front 训练标签生成。令目标、区域 mask 质心为 c_O, c_R ，图像宽高为 W, H_I ，则

$$\begin{aligned} G_1 &= |M_O|/(WH_I), \\ G_2 &= \frac{\|c_O - c_R\|}{\sqrt{(W-1)^2 + (H_I-1)^2}}, \\ G_3 &= \bar{c}_O - \bar{e}_{T,L} \in [-1, 1]^2. \end{aligned} \quad (23)$$

其中横纵坐标分别按宽高归一化。 $\bar{e}_{T,L}$ 是在该归一化坐标内拟合 tool mask 的 PCA 主轴，取投影极值确定两端，再选择图像 x 较小的端点。它不是工具质心，也不保证等于物理有效接触端。

目标缺失时仍监督 $G_1 = 0$ ；组成关系的任一 mask 缺失时屏蔽 G_2 或 G_3 。用 v_i 表示有效性，类质量映射为

$$w(q) = \min(q/0.95, 1), \quad q \in [0, 1]. \quad (24)$$

面积组使用目标权重；距离和向量组分别使用两相关类别权重的最小值。令元素权重为 ω_{bi} ，则

$$L_G = \frac{1}{3} \sum_{g=1}^3 \frac{\sum_{b,i \in g} \omega_{bi} \ell_{0.01}(\hat{G}_{bi} - \tilde{G}_{bi})}{\max(1, \sum_{b,i \in g} \omega_{bi})}, \quad (25)$$

其中 ℓ_β 为 Smooth L1。先组内归一化，避免二维向量仅因维度更多而占双倍组权重。总损失为

$$L_{\text{base}} = L_{\text{ACT},L1} + \lambda_{\text{KL}} L_{\text{KL}} + \lambda_G L_G, \quad (26)$$

当前 $\lambda_G = 1$ 。训练使用示范动作的 VAE 分支，推理不访问专家未来动作。

该监督使几何可读出，未显式监督注意力图，也未强制动作 decoder 只由几何决定。因此命题1的读出误差不可忽略。本模块不直接输出任务完成布尔值，不把质心距离当作完整区域包含判据。

E. 当前观察、慢语义与历史缓存

基础策略训练完成后冻结全部权重。残差变体 A 使用普通双 RGB ACT；B 使用双视角 U-Net 语义 ACT；C 使用双视角 QToken ACT。每次快更新只编码新 front/side 图像，完整视野缩放到 320×180 ，复用冻结 ResNet 并空间池化为每视角 $2 \times 3 \times 512$ ，合计 6144 维。

B 额外从最新两路分割概率提取池化概率、面积、质心、置信度、可见性和目标-区域/目标-工具质心关系，共 138 维。几何无效时零占位加 validity，不把零当作有效距离。该处工具关系不同于式(23)的端点向量。

C 通过原几何头的输入获取三个 512 维 query 隐藏状态，附三个数值有效标志，共 1539 维。它们绑定基础计划身份，只在对应计划生效后使用；不是每次快更新重新产生 query。当前 RGB 是新观察，query 是慢语义上下文。数值有效不表示目标可见或语义正确。

控制上下文 c_t 包含 follower 关节、因果估计速度、上一条已发送指令、对应未来基础动作及其与当前关节的差、槽位有效性、计划年龄、观察间隔、切换标志和目标延迟。 v_2 纳入 9 个基础动作，10 关节时共 223 维。训练时上一条指令取示范；运行时取实际返回指令，这一分布差异不被隐藏。

缓存最近 $W_h = 8$ 条 (f_i, c_i) ，每次在该窗口内从零状态计算

$$\begin{aligned} x_i &= \rho_\theta([\alpha_\theta(f_i), c_i]), \\ h_i &= \text{GRU}_\theta(x_i, h_{i-1}), \quad h_{\text{start}-1} = 0. \end{aligned} \quad (27)$$

视觉投影及输入投影为 128 维，GRU 为单层 hidden128。历史视觉特征不重复编码；但 GRU 每次重算窗口，不跨调用无限保留隐藏状态。正常 5Hz 下历史首尾约 1.4 秒；间隔超过 0.3 秒或任务 reset 时清空。

F. 有界残差监督与分阶段训练

残差头输出 $H \times n_a$ 调整量，在原生命令空间定义

$$\delta a_{t,j} = b \odot \tanh([W_r h_t + c_r]_j), \quad \hat{a}_{t,j} = a_{t,j}^{\text{base}} + \delta a_{t,j}. \quad (28)$$

初始 W_r, c_r 为零， $b_i = \text{clip}(\text{P95}_{\text{train}} |a_i^{\text{demo}} - a_i^{\text{base}}|, 0.05, 5)$ 。数据值为校准后的原生命令单位，不称作角度。限幅不替代位置、速度、加速度或碰撞安全约束。

以 m_{bj} 表示有效目标槽位，残差损失为

$$L_R = \frac{\sum_{b,j,i} m_{bj} \left[\ell_{0.1} \left(\frac{\hat{a}_{bj,i} - a_{bj,i}^{\text{demo}}}{\sigma_i} \right) + \lambda_R \left(\frac{\delta a_{bj,i}}{\sigma_i} \right)^2 \right]}{n_a \max(1, \sum_{b,j} m_{bj})}, \quad (29)$$

其中 $\lambda_R = 10^{-3}$ 。监督为原数据集 leader action，而非 future follower state 差。仅训练新增投影、GRU 和残差头。固定特征离线按 episode 缓存，保留配置和源模型指纹；训练/验证按 episode 分开，历史不跨轨迹，尾部目标 mask 无效。

训练使用 AdamW、学习率 10^{-4} 、weight decay 10^{-4} 、batch128、梯度裁剪 1，最多 50 轮、验证连续 8 轮无改善早停。best 按验证标准差缩放 MAE 选择。因此平方风险命题提供解释而非实际优化等价性。A 的当前记录 MLP 作为无窗口对照，仍含速度和上一动作，不能称作完全无时间信息。

G. 计划绑定、重叠更新与失效处理

当前配置为 $\Delta = 1/30$ 秒、 $K = 60$ 、慢观察间隔 30 帧， $s = 6, d = 3, H = 9$ 。例如第 6 帧观察对应第 9–17 帧，第 12 帧对应第 15–23 帧。式(18)决定迟到时丢弃的前缀；相邻预测重叠 3 帧。每次都以原基础计划相加，不在已经修正的动作上累加新残差。

结果必须携带 plan ID、目标槽位和原观察时间。新结果只覆盖同计划同目标时间的未执行槽位；每个旧槽位保留自己的时间，防止被新结果错误续期。新计划生效时清空旧残差；不同步、重复、非有限或过旧观察不视为新反馈。结果返回时最大观察年龄 0.15 秒，已接受残差使用年龄上限 0.4 秒，后者覆盖最远 11/30 秒目标，与命题4一致。

慢计划 ready 时间至少包含设定的 3 帧延迟，并在 shadow 中考虑实际测得的慢推理耗时。新计划未到时仅继续有效旧计划；基础计划也失效时返回无命令。实际机器人遇到无命令的安全处置必须由硬件控制层另行定义。当前代码提供离线训练与 shadow 数组输出，不将其等同于已部署的并发实时控制器。

H. 方法与理论假设的对应

标签迭代针对式(8)的真实几何噪声，但评分未经概率校准；几何辅助监督针对式(7)中的读出能力，不能自动保证动作利用；窗口 GRU 近似历史信息，其收益要求式(14)成立；零初始有界输出允许保留基础策略，但实际改善需要式(16)；时间戳、计划绑定与覆盖检查用于保证分析中修正对应的是同一个目标动作。上述映射明确了设计意图与待检验条件，不以模块存在代替条件成立。

V. 实验

参考文献

- [1] C. R. Shalizi, “Model-agnostic prediction,” Carnegie Mellon University, Data over Space and Time, Lecture 24, 2020. [Online]. Available: <https://stat.cmu.edu/~cshalizi/dst/20/lectures/24/lecture-24.html>
- [2] M. Mézard and A. Montanari, *Information, Physics, and Computation*. Oxford University Press, 2009. [Online]. Available: <https://web.stanford.edu/~montanar/RESEARCH/BOOK/partA.pdf>
- [3] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” arXiv:2304.13705, 2023. [Online]. Available: <https://arxiv.org/abs/2304.13705>
- [4] K. Sendai, M. Alvarez, T. Matsushima, Y. Matsuo, and Y. Iwasawa, “Leave no observation behind: Real-time correction for VLA action chunks,” arXiv:2509.23224, 2025. [Online]. Available: <https://arxiv.org/abs/2509.23224>
- [5] N. Ravi *et al.*, “SAM 2: Segment anything in images and videos,” arXiv:2408.00714, 2024. [Online]. Available: <https://arxiv.org/abs/2408.00714>