

面向遮挡接触操作的语义进展表示 与历史条件动作块纠偏

Abstract—遮挡接触操作要求机器人不仅生成连贯运动，还要区分目标暴露、接触与运输等任务状态，并在动作块执行期间响应环境变化。本文研究在有限示范、较少额外语义标注及受限在线计算下，如何增强模仿策略的任务完成能力，而不预设特定网络分工。针对同一动作预测目标，我们给出新增 RGB 的条件均值收益、几何监督表示的比较界，以及历史条件残差的风险改进条件，明确表示与拟合误差可能抵消理论收益。分析导向一个分阶段学习框架：质量驱动的自动语义标注产生几何监督，冻结分割器与几何监督查询 token 构建慢策略，再以最新视觉、控制上下文及历史缓存学习绑定目标执行时间的有界动作残差。本文明确这些分析不保证任意分割、任意记忆网络或任意残差都改善任务成功率。实机评估已观察到语义输入、任务相关 token 和 GRU 残差的效果；本文以条件性理论解释这些收益，并组织跨平台与受控对照验证其适用范围。

Index Terms—模仿学习，遮挡操作，语义表示，动作块，历史条件残差

I. 引言

双臂遮挡操作包含一组相互依赖的交互：移开遮挡物以发现目标，将两者分离，把目标运输至指定区域，并恢复遮挡物。外观相近的画面可能对应不同的接触关系或任务历史；同一个先前合理的推动动作，也可能在目标移动或重新遮挡后不再合适。因此，任务的难点不仅是复现示范轨迹，而是在执行过程中持续判断当前交互关系是否支持继续执行原有动作。

动作块模仿学习通过一次预测多步动作提高运动连贯性，ACT 是其中一种代表 [1]。这类方法可以周期重规划，并非天然没有反馈。然而，当计划以较低频率更新、而中间若干动作按原计划执行时，新发生的接触变化无法立即影响这些指令。同时，动作回归本身不要求内部表示显式区分目标可见程度、目标与工具的相对位置，或任务是否已接近完成。这使得拨空气、错过接触后继续推动和完成附近的无效运动成为需要分析的行为，而非仅以平均动作 loss 描述的误差。

本文提出的研究问题是：在有限示范与较少额外人工标注下，如何利用可得观测与交互历史，学习与真实任务状态相适应的动作，提高遮挡接触操作的完成能力？输入图像、任务相关 token 和历史条件残差是达到这一共同目标的不同途径，而不是三个互不相关的任务。我们将其拆成两个互补缺口。其一是有有限样本下任务相关关系可能未被可靠编码的表示缺口；其二是计划观测已经陈旧、当前单帧又可能无法辨别运动趋势的反馈缺口。两个缺口不能互相替代：准确分割不会自行更新旧动作，增加反馈频率也不能保证模型学会辨别错误接触。

已有研究表明，模型能否解释监督输入本身需要检验 [2]；多模态模仿学习也需要区分数据构建、观测模态与执行机制各自的作用 [3]。本文据此将标签可靠性与在线反馈分别建模，不把增加输入模态作为充分论据。

我们的分析以同一动作预测风险为基础，分别给出三种改进条件。新增 RGB 的条件均值信息收益必须超过编码和学习代价；同帧语义图虽不创造新信息，但通过几何监

督可以改善任务相关表示，当其表示与读出误差上界低于基线信息损失下界时，获得严格比较保证；历史条件残差则在可预测误差能量超过记忆编码与拟合损失时改善基础预测。这些结论解释何种条件足以支持改善，不把实机观察到的提升直接改写为无条件定理。

据此，方法包含一条连续的信息链：通过自主提示、SAM2 传播、质量诊断及局部迭代构建标签；训练冻结 U-Net 提供在线语义；以几何监督查询 token 将任务关系写入 ACT 表示；最后冻结慢策略，以最新视觉、慢语义上下文和因果历史训练有界 GRU 残差。这里的进展表示是可测的几何线索，不等同于完整阶段状态机或独立完成检测器。任务级进展能力应由事件附近的行为、可读出准确率及对应干预实验共同支持。

本文围绕三个研究要点组织论证：第一，将遮挡接触操作中的统一学习目标形式化，给出观测、语义表示与历史残差的条件性比较保证；第二，构建从低人工成本语义监督到几何表示，再到时间对齐历史残差的模块化方法；第三，分别检验标签可靠性、几何利用、新观测与历史贡献、以及时延下的纠偏效果，并以跨平台任务结果评估其实际价值。标准条件期望恒等式、一般残差结构和 GRU 单元本身不作为独创贡献。已有实机测试支持语义输入、任务相关 token 及 GRU 残差设计的效果，本文进一步用理论条件解释收益来源；当前结果不能自动证明所有条件在任意任务成立。

II. 相关工作

III. 问题定义与性能改进的条件

A. 统一任务目标，不预设网络结构

机器人需要在遮挡与接触变化下完成暴露、分离、运输和遮挡物恢复。令隐状态为 x_t ，可得观测为 $o_t = (I_t, q_t)$ ，其中 I_t 可包含一个或多个视角的图像， q_t 为实际执行臂关节状态。环境满足未知的 $x_{t+1} = f(x_t, u_t, \xi_t)$ 、 $o_t = h(x_t, \nu_t)$ 。令 $\mathcal{H}_t$ 表示截至 t 可得因果观测、任务条件与已执行指令记录。任务目标是学习策略 π ，提高任务完成概率

$$J(\pi) = \mathbb{P}_\pi\{\Psi(x_{0:T}, u_{0:T-1}) = 1\}, \quad (1)$$

其中 Ψ 表示任务要求及失败约束，不由固定时间阶段替代。输入模态、内部表示、记忆单元和动作参数化均是实现该目标的选择，不属于问题定义的前提。

训练给定示范观测与指令。以训练动作标准差构成正对角矩阵 D ，对固定预测时刻 τ 定义 $Y = D^{-1}a_\tau^{\text{demo}}$ 。可以逐槽预测或联合预测动作块，以下先分析相同 τ 的监督风险

$$R(p) = \mathbb{E}_\mu \|Y - p\|^2. \quad (2)$$

假设评价分布 μ 固定，各变量二阶可积，训练后的参数固定，预测仅依赖允许的因果信息；或等价地，所有期望条件于训练数据与训练随机性。示范指令不是唯一最优控制。式(2)是模仿学习的代理目标，与式(1)不同；实际 L1

或 Smooth L1 训练亦不等同于平方风险优化。后文的保证指固定分布上的平方风险，不把它自动提升为任务成功率或稳定性保证。

B. 统一分析：信息、表示与动作读出

令 $\mathcal{O}$ 为所比较模型允许访问的信息并集生成的 σ 代数， $m_{\mathcal{O}} = \mathbb{E}[Y | \mathcal{O}]$ 。一个训练后的模型经编码得到 Z ，实际动作为 $p(Z)$ 。以 $m_Z = \mathbb{E}[Y | Z]$ 定义

$$\begin{aligned} a_Z &= \mathbb{E}\|m_{\mathcal{O}} - m_Z\|^2, \\ e_Z &= \mathbb{E}\|p(Z) - m_Z\|^2. \end{aligned} \quad (3)$$

a_Z 表示编码后无法恢复的动作相关信息， e_Z 包含有限数据、动作头表达能力及优化不足造成的读出误差。由条件期望正交性 [4]，

$$R(p) = R(m_{\mathcal{O}}) + a_Z + e_Z. \quad (4)$$

因此任意两种表示的实际风险差为

$$R(p_0) - R(p_1) = (a_{Z_0} - a_{Z_1}) + (e_{Z_0} - e_{Z_1}). \quad (5)$$

不要求两个已训练表示具有包含关系。信息更丰富、语义更清晰或记忆更长，都需要落实为这两类误差的净改善；仅增加模块数量不能推出净改善。

C. 路径一：RGB 观测何时提高预测性能

令 X 为基线已有输入， I 为新加入的原始 RGB 观测。 X 可以是关节与任务条件，也可以包含已有视角或较早图像；因此该分析也适用于补充视角或加入更新图像。定义 $m_X = \mathbb{E}[Y | X]$ 、 $m_{XI} = \mathbb{E}[Y | X, I]$ ，以及实际预测 $p_0(X), p_1(X, I)$ 的误差 $\varepsilon_0 = \mathbb{E}\|p_0 - m_X\|^2$ 、 $\varepsilon_1 = \mathbb{E}\|p_1 - m_{XI}\|^2$ 。

命题 1 (新增 RGB 的实际改进条件): 对相同目标与评价分布，有

$$\begin{aligned} R(p_0) - R(p_1) &= \Delta_I + \varepsilon_0 - \varepsilon_1, \\ \Delta_I &= \mathbb{E}\|m_{XI} - m_X\|^2 \geq 0. \end{aligned} \quad (6)$$

故 $\varepsilon_1 - \varepsilon_0 < \Delta_I$ 时实际模型严格改善。

证明由嵌套条件期望分解得到，见附录。理想预测器不因新增 RGB 而变差；严格理想收益要求 RGB 使条件动作均值发生变化，而不仅是图像包含更多像素。例如相同关节状态下，目标在工具不同侧需要不同指令，能够区分目标位置的图像可以减小观测歧义。但完全冗余、不同步或无关 RGB 可能使 $\Delta_I = 0$ ，有限训练误差也可能抵消信息收益。若保留原输入允许模型忽略新增 RGB，只能保证总体最优假设类不劣，不能保证实际优化自动达到它。

原 RGB 与语义 RGB 必须区分。若新增的是分割概率经调色板生成的语义 RGB 图 $S = g(I)$ ，且 I 已在 X 中，则

$$\sigma(X, S) = \sigma(X), \quad \mathbb{E}[Y | X, S] = \mathbb{E}[Y | X]. \quad (7)$$

这时不能套用严格新增观测收益；收益只能来自式(5)中的表示或读出误差降低。预训练分割引入的是由额外标签学到的先验，固定分割器后并不创造图像原本没有的信息。

D. 路径二：语义图与几何监督 token 的作用

原 RGB 保留完整可见细节；语义图显式组织对象类别和空间范围；几何监督 token 进一步要求特定的任务关系能够从内部表示读出。三者对应不同层次，不能把输入分割图与对 query 添加监督混成一个操作。

令 G 为真实任务几何， C 为必要控制条件。考虑存在一个对几何输入为 L_G -Lipschitz 的函数 f_G ，满足近似任务相关性

$$\mathbb{E}\|m_{\mathcal{O}} - f_G(G, C)\|^2 \leq \epsilon_{\text{suf}}. \quad (8)$$

不要求 G 单独足以决定动作； ϵ_{suf} 明确容纳未表示的接触、姿态和历史因素。在接触模式切换附近，该平滑性可能仅局部成立。设实际语义/query 表示为 Z_Q ，其允许输入包括 C ，辅助头给出 $\hat{G} = d(Z_Q)$ ，定义 $\epsilon_G = \mathbb{E}\|\hat{G} - G\|^2$ 。实际策略读出误差为 $e_Q = \mathbb{E}\|p_Q - \mathbb{E}[Y | Z_Q]\|^2$ 。

命题 2 (几何监督表示的比较保证): 上述条件下，定义 $U_G = (\sqrt{\epsilon_{\text{suf}}} + L_G \sqrt{\epsilon_G})^2$ ，则

$$R(p_Q) - R(m_{\mathcal{O}}) \leq U_G + e_Q. \quad (9)$$

若基线表示 Z_0 的信息损失有下界 $a_{Z_0} \geq \delta_0 > 0$ ，且

$$U_G + e_Q < \delta_0, \quad (10)$$

则 $R(p_Q) < R(p_0)$ ，不论基线自身读出误差是否为零。

证明: $f_G(\hat{G}, C)$ 对 Z_Q 可测，故条件均值读出的最优性给出 $a_{Z_Q} \leq \mathbb{E}\|m_{\mathcal{O}} - f_G(\hat{G}, C)\|^2 \leq U_G$ ；后一不等式由 L^2 三角不等式及 Lipschitz 条件得到。式(4)推出式(9)。基线风险满足 $R(p_0) - R(m_{\mathcal{O}}) = a_{Z_0} + e_{Z_0} \geq \delta_0$ ，故式(10)给出严格比较。

这个比较用本方法的上界对基线的下界，而非比较两个上界。一个足以产生 δ_0 的情形是：基线压缩了动作相关的对象关系，把需要不同动作的情况映射成相同表示；附录给出双模式混叠的定量下界。这并不声称现有 RGB ACT 必然发生这种混叠。如果基线已经保留充分信息， a_{Z_0} 可以为零，此保证便不能用于它；实际收益仍可能来自读出更容易，但必须由式(5)另行分析。

该命题可分别应用于 RGB 到语义 RGB 表示、语义表示到几何监督 query 表示的比较，每次需要使用各自基线与方法的误差条件，不能把第一步的下界直接用于第二步。语义标签相同但 query 监督不同的情况，主要区别在于关系可读出性和动作读出误差，而非新增类别信息。

为什么是带特定监督的 query？设三个 encoder query 状态为 z_i ，几何头为 d_i ，动作 decoder 读取包括这些 query 的上下文。对平方几何损失，其针对第 i 个 query 状态的直接梯度为

$$\nabla_{z_i} L_i = 2J_{d_i}(z_i)^\top (d_i(z_i) - \tilde{G}_i). \quad (11)$$

因此每个 query 接受一个可检验的关系读出约束，而非仅依赖动作 loss 自发分工；共享 encoder 训练使这个约束影响其从图像聚合的特征。实际 Smooth L1 将误差梯度替换为对应分段导数，监督目标仍是几何可读出性。将这些状态保留在动作 decoder 的可访问上下文中，提供利用所学关系的计算路径。这解释了关系监督加可访问 token 这一设计的作用，但不证明特定 attention 形式或恰好三个 query 优于所有其他结构，也不直接监督注意力图。对于理想梯度更新，附录还给出辅助几何更新相对仅动作更新的局部下降条件：几何更新必须与动作下降方向足够一致，收益才能超过二阶曲率代价。因此几何监督既可能改

善表示，也可能产生负迁移；任务 loss 的权重不能由语义正确这一事实单独决定。

若动作头忽略 query，几何仍可准确但 e_Q 未必小，严格改进条件不能仅由几何 loss 推得。因此，保留 e_Q 比假定辅助监督必然改变动作更必要。语义图压缩成三通道通常不可逆，共享 ImageNet 编码器也没有一般最优性保证；命题约束的是最终表示质量，不能把它当成这些具体工程选择的独立证明。

若监督来自伪标签 $\tilde{G} = G + \eta$ ，则

$$\epsilon_G \leq 2\mathbb{E}\|\tilde{G} - G\|^2 + 2\mathbb{E}\|\eta\|^2. \quad (12)$$

由此，低训练 loss 必须与标签真实误差共同考察。质量诊断、局部重试和少量人工复核针对后者；软权重不自动使标签无偏，其选择偏差见附录。对仅在对象可见时才可定义的距离关系，几何误差与比较界应在相应有效条件分布上使用。不可见样本不受该辅助 loss 约束，不能把可见子集上的保证直接扩展成全任务保证；总体风险还需加上无效子集的风险。面积为零可定义，与缺失的距离不是同一情形。若进展事件确实可表示为 $p_E(G) = \mathbf{1}\{\phi(G) \geq 0\}$ ，且 ϕ 为 L_ϕ -Lipschitz，则任意 $\gamma > 0$ 满足

$$\mathbb{P}[p_E(\tilde{G}) \neq p_E(G)] \leq \mathbb{P}[|\phi(G)| \leq \gamma] + L_\phi^2 \epsilon_G / \gamma^2. \quad (13)$$

这是有事件裕量时的可靠性界，不表示面积与质心距离已经完整表达任务完成。

E. 路径三：历史条件 GRU 残差何时改善动作

令 B 为已有模型对同一目标 Y 的预测， $e = Y - B$ 为待修正误差。此处才选择 $B + r$ 作为动作参数化；它不改变任务或监督目标。令 $\mathcal{F}_C$ 为当前输入、基础动作和控制上下文， $\mathcal{F}_H$ 为加入因果历史后的信息， $\mathcal{F}_C \subseteq \mathcal{F}_H$ 。定义 $m_C = \mathbb{E}[e | \mathcal{F}_C]$ 、 $m_H = \mathbb{E}[e | \mathcal{F}_H]$ 。由同一正交性有

$$R(B + m_C) - R(B + m_H) = \mathbb{E}\|m_H - m_C\|^2 =: \Delta_H. \quad (14)$$

如果历史区分了当前画面相似但需要不同纠正的运动/接触情况， $\Delta_H > 0$ 。历史仅改变预测方差、不改变条件均值时，平方风险下该增益仍可为零。当前上下文若已有速度或上一指令，这里的增益只指额外历史记录，而不是全部时间信息。

GRU 把历史编码成 h_t ，实际可用信息为 $\mathcal{T} = \sigma(B, C_t, h_t) \subseteq \mathcal{F}_H$ 。记 $m_{\mathcal{T}} = \mathbb{E}[e | \mathcal{T}]$ ，定义

$$\begin{aligned} \epsilon_{\text{enc}} &= \mathbb{E}\|m_H - m_{\mathcal{T}}\|^2, \\ \epsilon_{\text{res}} &= \mathbb{E}\|r - m_{\mathcal{T}}\|^2. \end{aligned} \quad (15)$$

前者包含观测特征压缩、短窗口与记忆编码损失，后者包含残差函数类及训练误差。

命题 3 (实际 GRU 残差的条件性保证): 对 $\mathcal{T}$ 可测的实际残差，有

$$R(B) - R(B + r) = \mathbb{E}\|m_H\|^2 - \epsilon_{\text{enc}} - \epsilon_{\text{res}}, \quad (16)$$

$$R(B + r) - R(B + m_C) = \epsilon_{\text{enc}} + \epsilon_{\text{res}} - \Delta_H. \quad (17)$$

故编码与拟合误差之和小于可预测残差能量时，实际残差严格优于基础模型；若更强地小于 Δ_H ，则严格优于最优的当前输入残差。

证明: $e - m_H$ 与所有平方可积历史可测函数正交，且 $m_H - m_{\mathcal{T}}$ 与所有平方可积 $\mathcal{T}$ 可测函数正交，故 $R(B + r) = \mathbb{E}\|e - m_H\|^2 + \epsilon_{\text{enc}} + \epsilon_{\text{res}}$ 。将 $R(B) = \mathbb{E}\|e\|^2$ 正交展开得到首式，结合式(14)得到次式。 ■

GRU 的门控提供选择性保留历史与更新状态的参数化路径；它的理论角色是逼近与纠偏相关的历史统计量，而非凭架构名称获得优势。若存在统计量 s_t 使 $m_H = F(s_t, B, C_t)$ ， F 对 s_t 为 L_s -Lipschitz，且从 GRU 表示中可读出 $\hat{s}_t$ 、 $\mathbb{E}\|\hat{s}_t - s_t\|^2 \leq \epsilon_s$ ，则

$$\epsilon_{\text{enc}} \leq L_s^2 \epsilon_s. \quad (18)$$

于是 $L_s^2 \epsilon_s + \epsilon_{\text{res}} < \Delta_H$ 是一个结构化的充分条件。证明同几何读出候选函数的投影论证。不假设 GRU 一定学到该统计量，也不以此证明 GRU 优于 LSTM 或 Transformer。

残差参数化让已有解 $r = 0$ 可直接保留，并把监督集中到基础误差；在无限表达能力下，它与直接预测动作具有相同的最优能力。严格收益依赖学习到的条件误差，而非加法本身。可直接测量的等价条件为

$$R(B) - R(B + r) = 2\mathbb{E}\langle Y - B, r \rangle - \mathbb{E}\|r\|^2 > 0. \quad (19)$$

限幅减少过大修正的可用范围，却不保证每次修正方向正确。时间错位或陈旧观测会改变残差条件与编码误差；对应时间管理放在方法与附录，不再作为任务定义或第四个独立研究目标。

F. 三个已观察到的收益对应何种保证

实机结果已支持三个设计在当前测试任务中的效果，本节说明这些效果何时具有一致的数学解释，而不将它们重述为尚未实现的设想。新增原 RGB 的保证来自条件均值信息收益超过实现代价；语义 RGB 与几何 query 的保证来自任务相关表示误差及读出误差的净降低；历史 GRU 残差的保证来自可预测误差能量超过编码和拟合损失。这些是有明确条件的比较结论，并非从既有成功率反推所有假设必然成立。基础概率恒等式不是本文新的数学发现，具体贡献应体现为这些条件指导的监督、信息路径与纠偏实现，以及对实机收益来源的解释。

IV. 语义进展表示与历史条件纠偏

A. 总体信息流与训练边界

方法以 ACT 作为慢策略，输出基础动作块；以轻量 GRU 为快分支，输出相同目标槽位的局部修正。两者承担不同职责：慢策略组织连贯运动并编码任务几何，快分支利用更近的观测和历史调整当前计划。动作空间残差的通用思想已有研究 [5]，动作块实时修正也已有专门工作 [6]。本文研究语义监督、条件历史与时间对齐的组合如何影响遮挡接触任务中的动作块执行，而非重新提出一般残差控制结构。

训练分三步：先构建标签并训练分割器；再冻结分割器训练语义 ACT 及几何 query；最后冻结整个基础策略，只训练快分支。在线不运行 SAM2 或读取数据集 mask。三个阶段共享预先确定的 episode 划分，任何作为全系统未见测试的 episode 不得用于分割训练、提示器训练、策略训练、阈值选择或 checkpoint 选择。若已有 checkpoint 不满足统一划分，其结果只能按实际已见条件报告。

B. 把伪标签噪声控制前移

为降低式(12)中的标签噪声，首先将类别说明与代表帧转换为 AI 生成的稀疏框/点 JSON 提示，渲染后人工审核。SAM2 [7] 传播少量种子视频；对目标初现、接触及再遮挡片段补充提示并局部重跑。审核标签转为检测框后训练分

视角 YOLO 提示器，用于扩大标注范围，再进入诊断与修复循环。

诊断包括邻帧 IoU、面积突变、质心跳变、连通域异常，以及可用时的正反传播一致性。各项按类别阈值归一化为分数，连同预期可见性、缺失项和人工例外独立保存。低可信片段进入自动重试或少量人工复核；真实暴露事件不能仅因面积突变被删除。分数用于定位风险而非宣称已校准的不确定概率；一致但错误的类别仍需独立审核。双向结果使用未来帧，严格限制在离线标注中。

标签质量影响三个不同环节：离线修复、提示器样本构建、以及下述几何辅助监督。当前独立 U-Net 训练采用类别加权 CE 与配置的前景 Dice，不默认把每帧质量分数自动乘入分割 loss。论文需分别记录各环节实际启用的机制，避免将整个流程笼统称为概率不确定性端到端学习。人工时间、提示修改次数和残余标签错误应共同计入成本收益。

C. 共享视觉编码的语义动作块策略

分别为 front 和 side 训练轻量 U-Net，保留对应视角类别数，不强制类别数相同。当前任务 front 含背景共 7 类，side 含背景共 5 类；同名类别使用一致调色板。完整视野缩放到 480×270 后分割，策略训练和运行中均冻结分割器。对概率 $P_t^v(c, u)$ ，语义图定义为

$$S_t^v(u) = \sum_{c=1}^{C_v} P_t^v(c, u) p_c, \quad p_c \in [0, 1]^3. \quad (20)$$

这是概率加权颜色，不是硬 argmax；多类别到三通道的映射一般不可逆。每个视角的 RGB 和语义图分别经过同一个 ResNet18 及投影，作为独立视觉 token 输入 ACT encoder，保留原 ACT 位置编码，不增加 camera 或 modality embedding。单视角包含两路视觉输入，双视角包含四路。保留 RGB 是为了避免语义瓶颈丢弃姿态、机械臂外观及其他没有标入类别的控制信息。

本结构是对几何归纳偏置的实用实现，不声称共享编码器最优。同参数或同 token 预算的重复 RGB 对照应排除仅由额外计算带来的收益。当前不进行跨视角三维配准，也不将 side 分割变换为补全后的 front 图。

D. 用几何监督定义 query 职责

在 encoder 中加入三个可学习初始向量 $e_i \in \mathbb{R}^{512}$ 。它们与视觉、关节及 ACT 原有 token 共同进行自注意力，产生观察相关表示 z_i 。线性头 $d_i(z_i)$ 分别预测以下 front 图像几何：

$$\begin{aligned} G_1 &= |M_O|/(WH_I), \\ G_2 &= \|c_O - c_R\|/\sqrt{(W-1)^2 + (H_I-1)^2}, \\ G_3 &= \bar{c}_O - \bar{e}_{T,L} \in \mathbb{R}^2. \end{aligned} \quad (21)$$

M_O 为目标可见 mask， c_O, c_R 为目标和区域质心；横纵归一化坐标用上横线表示。将 tool mask 在归一化平面上做 PCA 主轴拟合，取投影极值的两个端点，选择横坐标较小者 $\bar{e}_{T,L}$ 。该定义保留目标与工具端点的二维方向关系，但图像左端点不必总是实际接触端，需在对应装置与视角下验证。

目标不可见时仍监督面积为零；组成关系的任一 mask 不可见时不监督相应距离或向量。令 v_{bi} 表示该组可定义，

q_{bi} 为相关类别质量的最小值， $\omega_{bic} = v_{bi} \min(q_{bi}/0.95, 1)$ 为复制到各坐标 c 的权重，则

$$L_G = \frac{1}{3} \sum_{i=1}^3 \frac{\sum_{b,c} \omega_{bic} \ell_{0.01}(\hat{G}_{bic} - \tilde{G}_{bic})}{\max(1, \sum_{b,c} \omega_{bic})}. \quad (22)$$

此处 $\hat{G}_{bi} = d_i(z_{bi})$ ，三组维度为 1、1、2；先按有效坐标权重归一化，再对三个组取平均，与当前实现一致。由于分母同样加权，所有样本同倍降权可能被抵消，不能称其为整体 loss 的绝对衰减。ACT 学习目标为

$$L_{\text{slow}} = L_{\text{action}, L1} + \lambda_{\text{KL}} L_{\text{KL}} + \lambda_G L_G, \quad (23)$$

当前配置 $\lambda_G = 1$ 。动作 decoder 读取完整 encoder 上下文，包括 query 隐藏状态。几何 loss 更新 ACT 表示但不更新冻结 U-Net。

该设计对应式(9)的几何读出路径；要得到严格比较，还需式(10)中的基线信息损失与实际读出误差条件。它不是监督 attention map，也不是把预测几何四个数直接作为唯一动作输入。辅助头是否准确与动作是否依赖 query 必须分别检验。当前模型不额外学习阶段分类、切换或停止头；可见性、分离和区域包含等事件用于独立评价其任务进展行为，而不是添加未经实现的控制规则。

E. 最新观察与短期历史的增量反馈

基础策略冻结后，每次快更新只处理新到达的双视角 RGB，完整视野缩放到 320×180 ，复用冻结视觉骨干并池化为每视角 $2 \times 3 \times 512$ 特征。不重复编码窗口内旧图像。控制上下文 c_t 包括实际 follower 关节、因果估计速度、上一发送指令、对应基础未来动作及相对当前关节的差、槽位有效性、计划年龄、观察间隔与计划切换信息。显式提供基础目标动作，使快分支预测的是该计划的误差。

以三个分支进行模块化研究：A 使用普通 RGB ACT 及最新 RGB；B 使用语义 ACT，并在每次快更新运行双 U-Net 得到最新语义描述；C 使用 QToken ACT，将当前生效慢计划的三个 query 隐藏状态作为语义上下文，并结合最新 RGB。B 额外描述包含概率池化、面积、质心、可见性及关系有效性；C 的 query 并非每次快更新重新计算，也不是最新语义观测。数值有效标志不能充当分割可信度。

三者使用共同的历史编码形式。对最近 $N_h = 8$ 条记录

$$h_i = \text{GRU}_\theta(\rho_\theta(f_i, c_i), h_{i-1}), \quad h_{\text{start}-1} = 0. \quad (24)$$

视觉及输入投影为 128 维，GRU 为单层 hidden128。每次从窗口起点重算 GRU，不跨调用无限延续隐藏状态；5Hz 时 8 条记录覆盖约 1.4 秒。reset 或超过 0.3 秒的记录断流清空窗口。历史编码旨在降低式(16)的有效编码误差，但其实际收益须与同输入最新记录 MLP、历史置乱和窗口长度对照区分。

F. 有界动作残差与监督

快头输出 H 个动作修正，在机器人原生命令单位中定义

$$\delta a_{t,j} = \beta \odot \tanh([W_r h_t + c_r]_j), \quad \hat{a}_{t,j} = b_{t+d+j}^{(k)} + \delta a_{t,j}. \quad (25)$$

输出层零初始化，初始等于基础策略。每维 β_i 由训练基础误差绝对值 P95 设定，当前裁剪到 $[0.05, 5]$ 原生命令单位；换平台必须核对单位和尺度，不能直接称为角度。限幅约束局部修改范围，不保证动力学安全。

令 m_{tj} 为有效监督槽位，动作维度为 n_a 。定义标准差缩放误差 $e_{tji} = (\hat{a}_{tji} - a_{t+d+j,i}^{\text{demo}})/\sigma_i$ 、 $r_{tji} = \delta a_{tji}/\sigma_i$ ，学习目标为

$$L_R = \frac{\sum_{t,j,i} m_{tj} [\ell_{0.1}(e_{tji}) + \lambda_R r_{tji}^2]}{n_a \max(1, \sum_{t,j} m_{tj})}. \quad (26)$$

各项按动作维度归一化，当前 $\lambda_R = 10^{-3}$ 。训练数据使用 leader 示范指令作为目标，follower 关节作为观测，不混用此前 delta 实验。只训练新增投影、GRU 和残差头；特征可按 episode 离线缓存，尾帧屏蔽无效目标。上一指令训练时取示范，实时时为实际发送值，这一分布差异需在闭环中评价。AdamW 学习率 10^{-4} 、batch128、最多 50 轮，验证 8 轮无改善早停；按验证标准差缩放 MAE 选 checkpoint，平方风险另作机制诊断。

G. 执行时间对齐与局部重叠

当前实例使用 30Hz 控制，慢策略输出 60 步、每 30 步更新基础计划；快分支每 6 帧更新，延迟偏移 $d = 3$ ，输出 $H = 9$ 。例如第 6 帧观察对应第 9 至 17 帧修正，第 12 帧观察对应第 15 至 23 帧修正。相邻轮次重叠 3 帧；及时应用首槽的端到端预算为 100ms。

所有结果携带 plan ID、观察时间和目标槽位。新结果仅替换同计划同槽位的未执行残差，始终加到原基础动作上，不向已经修正的动作累加。迟到按式(32)丢弃前缀；新计划生效清空旧残差，重复、非有限和失效观察不更新反馈。当前接受结果的最大观察年龄 0.15 秒、残差使用年龄上限 0.4 秒。因此实际接受规则可能比纯覆盖界更严格，必须计入实测可用覆盖率。所有参与结果接受的时序状态均属于运行记录；分析中应纳入相应可用信息集。

残差无效而基础槽位有效时回退原计划；两者都无效时由硬件层执行已验证的安全处置，不能无限复用最后一个动作。端到端预算包括图像传输、预处理、编码、排队及命令发布，不能以 GRU 单次 GPU 耗时替代。本文方法规格须与每次实机部署版本核对；离线 shadow 通过不自动等价于真实硬件实时验证。

V. 实验：问题与验证对应

在已有实机测试支持三个设计有效的基础上，实验按表示收益、反馈收益和任务表现组织，并用于核对理论条件与收益来源：首先在独立人工审核的分层视频子集上，对比自动标注迭代前后及质量诊断消融，报告人工时间、各类 mask 与几何误差，并单列接触、初现和重遮挡片段，检验式(12)及质量选择偏差；其次在相同示范、视角、种子和训练预算下，对比 RGB ACT、语义 ACT、无几何监督的同结构 query 及完整 QToken，加入重复 RGB 的 token 预算对照，报告动作误差、几何读出和事件附近行为，以受控遮挡及 query 干预辅助检验式(9)中的相关性与利用路径，事件真值独立审核，不能以同一预测 mask 自证任务完成；再次固定同一基础 checkpoint、目标槽位和调度，比较零残差、仅计划上下文残差、最新观察 MLP、无额外历史的同结构 GRU 及完整历史 GRU，并用历史置乱、移除慢 query 和残差开关区分新观察、历史及语义贡献，报告式(19)的实测两项、逐关节及计划年龄误差，不将不可直接观测的 Bayes 风险项当作已测量数值；随后注入可控延迟与丢帧，在相同设备负载下比较慢重规划、频繁完整 ACT 与快残差的时延分位数、目标槽覆盖率和恢复表现，检验式(33)的适用范围；最后在两个真实平台的多类

任务、配对初始条件和受控扰动下评价全系统成功率、事件到达率、拨空气次数、恢复率、完成后无效动作及任务耗时，统一超时规则并计入失败，使用多个训练种子和重复实机试验报告分层置信区间。跨 A/B/C 的全链路对比不能独立归因于快分支输入，相关消融须固定基础策略；未见对象/布局的划分应贯穿提示器、分割器和策略训练，模拟实验仅作为可选的隐状态与延迟控制验证，不替代实机结果。

VI. 讨论与适用边界

本方法适用于目标关系能够由视觉近似表达、至少部分关键变化在反馈窗口内可观测，且基础策略误差仍处于局部可修正范围的任务。双视角可以增加真实观测信息，但本实现不恢复三维状态或不可见表面；相机布局改变需要重新验证。接触力、材料状态及完全遮挡目标可能无法由当前几何量辨别；示范缺少失败恢复时，残差不具备任意状态恢复能力。共享视觉编码、三通道语义映射和 GRU 均是实现选择，不是理论唯一解。理论分析约束论证与实验，不将平方动作误差改善等同于闭环稳定性、碰撞安全或必然完成。

Appendix A

统一分解、RGB 增益与混叠下界

对任意 Z 可测预测 p ，条件期望正交性给出 $R(p) = R(m_Z) + \mathbb{E}\|p - m_Z\|^2$ 。再对 $\sigma(Z) \subseteq \mathcal{O}$ 使用正交性，即得式(4)。对 $\sigma(X) \subseteq \sigma(X, I)$ ，同理 $R(m_X) - R(m_{XI}) = \mathbb{E}\|m_{XI} - m_X\|^2$ ，加上两模型各自误差即得命题1。

命题2所需的基线下界可以由动作相关的表示混叠得到。假设存在 Z_0 可测事件 A ， $\mathbb{P}(A) = \rho > 0$ ；在 A 上，给定 Z_0 后， $m_{\mathcal{O}}$ 等概率取 $u_1(Z_0), u_2(Z_0)$ ，且二者距离至少 $d_0 > 0$ 。则条件方差为 $\|u_1 - u_2\|^2/4$ ，故

$$a_{Z_0} = \mathbb{E}\|m_{\mathcal{O}} - m_{Z_0}\|^2 \geq \rho d_0^2/4. \quad (27)$$

如果语义/query 表示能以足够小的误差区分这两类关系，满足 $U_G + e_Q < \rho d_0^2/4$ ，便获得严格风险改善。这个例子限定的是基线表示混叠，不声称完整 RGB 本身无法辨别两者。若原图也完全一样且没有额外历史/视角，则确定性语义不能凭空消除该歧义。

对事件界(13)，在 $|\phi(G)| > \gamma$ 时，判定翻转要求 $L_\phi \|\hat{G} - G\| > \gamma$ ；由 Markov 不等式再加阈值邻域概率可得。

Appendix B

query 辅助监督的局部优化条件

令 $A(\theta)$ 为动作损失， $G(\theta)$ 为几何辅助损失。在可微且 ∇A 在相关更新线段上为 L_A -Lipschitz 的区域，考虑理想梯度更新 $\theta_a = \theta - \eta \nabla A(\theta)$ 与 $\theta_q = \theta_a - \eta \lambda \nabla G(\theta)$ ，其中 $\eta, \lambda > 0$ 。从 θ_a 沿第二项积分梯度并使用 Lipschitz 界，有

$$A(\theta_q) - A(\theta_a) \leq -\eta \lambda \langle \nabla A(\theta_a), \nabla G(\theta) \rangle + \frac{1}{2} L_A \eta^2 \lambda^2 \|\nabla G(\theta)\|^2. \quad (28)$$

因此若两梯度内积大于 $L_A \eta \lambda \|\nabla G(\theta)\|^2/2$ ，联合更新的动作损失严格低于同一步的仅动作更新。这里直接比较实际 $A(\theta_q)$ 和 $A(\theta_a)$ ，不是比较两个分别计算的下降上界。query 几何头提供这种辅助梯度的明确来源，但不保证内积为正。该条件是局部优化结论；用于经验 loss 时不等

于泛化保证，也不保证整个训练轨迹。当前自适应优化器不等于上述理想梯度更新，若检查其实际一步效果需使用对应的有效参数更新和相同优化器状态，而不能照搬 $\eta\lambda\nabla G$ 。

Appendix C 质量加权的偏差与有界残差

对辅助输入 V 、权重 $W \in [0, 1]$ ，在 $\mathbb{E}[W | V] > 0$ 的支持集上，加权平方损失的总体最优解为

$$f_W(V) = \frac{\mathbb{E}[W\tilde{G} | V]}{\mathbb{E}[W | V]}. \quad (29)$$

若 $\tilde{G} = G + \eta$ ，则

$$f_W - \mathbb{E}[G | V] = \frac{\text{Cov}(W, G | V) + \mathbb{E}[W\eta | V]}{\mathbb{E}[W | V]}. \quad (30)$$

因此高质量筛选可能同时降低噪声并偏向容易样本，不能只保留前一种解释。这是平方损失的总体诊断，非实际组归一化 Smooth L1 的等价解。

令残差条件均值为 m_T ，条件正交性给出

$$R(B) - R(B + r) = \mathbb{E}\|m_T\|^2 - \mathbb{E}\|r - m_T\|^2. \quad (31)$$

如果残差限定在含零的盒 $\mathcal{C}$ ，平方风险总体最优解为 $\Pi_{\mathcal{C}}(m_T)$ ，因零可行而不劣于基础策略。有限数据训练不一定达到该解， $\tanh$ 限幅也不保证每个状态的改进。

Appendix D 时间对齐的实现条件

控制周期为 Δ ，观察间隔为 s 帧，预测从观察后第 d 帧开始的 H 个残差。结果到达延迟为 ℓ ，仅在目标槽截止时刻或之前可用才允许使用，则过期前缀为

$$k = \min\{H, \max(0, \lceil \ell/\Delta \rceil - d)\}. \quad (32)$$

第 n 轮目标区间为 $[ns + d, ns + d + H - 1]$ 。下一轮首个未过期槽为 $(n + 1)s + d + k$ ；不晚于前轮末槽的下一帧要求

$$s + k \leq H, \quad k < H. \quad (33)$$

它假设前轮完整有效、无跨计划切换和额外年龄拒绝。发生额外失效时统计真实覆盖，不能继续引用理想连续覆盖结论。所有比较均使用同一基础动作 B 与同一目标 Y ；错位应用不是在原推导中简单增加一点残差噪声，而是改变了监督与执行对应关系。

Appendix E 动作风险保证与任务成功保证的区别

式(1)涉及策略诱导的闭环状态分布；本文风险比较使用固定 μ 。局部动作 MSE 下降不能直接证明更高成功率：某些小误差可能发生在关键接触点，另一些大误差在自由空间可能无害；多模态示范的条件均值也未必是安全动作。要进一步证明任务成功，需要额外的可控性、接触模式、误差传播、成功集合裕量及策略访问分布约束。当前不具备这些已验证前提，因此不制造全局收敛定理。已经得到的实机收益是任务级证据；本节理论为其提供条件性机制解释，而不是用未经成立的动力学假设替代该证据。

参考文献

- [1] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, "Learning fine-grained bimanual manipulation with low-cost hardware," arXiv:2304.13705, 2023. [Online]. Available: <https://arxiv.org/abs/2304.13705>
- [2] A. Bobu, A. Bajcsy, J. F. Fisac, S. Deglurkar, and A. D. Dragan, "Quantifying hypothesis space misspecification in learning from human-robot demonstrations and physical corrections," *IEEE Transactions on Robotics*, vol. 36, no. 3, pp. 835–854, 2020. [Online]. Available: <https://arxiv.org/abs/2002.00941v2>
- [3] T. Ablett, O. Limoyo, A. Sigal, A. Jilani, J. Kelly, K. Siddiqi, F. Hogan, and G. Dudek, "Multimodal and force-matched imitation learning with a see-through visuotactile sensor," *IEEE Transactions on Robotics*, vol. 41, pp. 946–959, 2025. [Online]. Available: <https://arxiv.org/abs/2311.01248v5>
- [4] C. R. Shalizi, "Model-agnostic prediction," Carnegie Mellon University, Data over Space and Time, Lecture 24, 2020. [Online]. Available: <https://stat.cmu.edu/~cshalizi/dst/20/lectures/24/lecture-24.html>
- [5] A. Zeng, S. Song, J. Lee, A. Rodriguez, and T. Funkhouser, "TossingBot: Learning to throw arbitrary objects with residual physics," *IEEE Transactions on Robotics*, vol. 36, no. 4, pp. 1307–1319, 2020. [Online]. Available: <https://arxiv.org/abs/1903.11239v3>
- [6] K. Sendai, M. Alvarez, T. Matsushima, Y. Matsuo, and Y. Iwasawa, "Leave no observation behind: Real-time correction for VLA action chunks," arXiv:2509.23224, 2025. [Online]. Available: <https://arxiv.org/abs/2509.23224>
- [7] N. Ravi *et al.*, "SAM 2: Segment anything in images and videos," arXiv:2408.00714, 2024. [Online]. Available: <https://arxiv.org/abs/2408.00714>