

Semantic-Guided Imitation Learning with History-Conditioned Feedback: Analysis, Framework, and Experimental Validation

Abstract—双臂遮挡交互操作需要在非线性接触与动态可见性变化中完成多阶段目标。初步实机实验观察到语义输入、几何监督查询和历史条件残差带来的任务收益。本文以这些现象为出发点，研究哪些机制能够解释收益，并指导下一步受控验证。首先将任务定义为视觉可评估的对象关系和环境状态条件，不预设网络分工；在这一目标下，利用有限时域性能差分恒等式，建立动作误差与任务失败概率之间的条件性界，显式区分泛化、状态覆盖和动作误差的任务敏感性；并用反例说明完整覆盖仍不足以保证策略排序一致。随后，分析确定性语义输入与几何监督查询 token 作为归纳偏置的作用，以及最新观测和短期历史能够被残差预测器利用的条件。最后，讨论动作时间集成的偏差与相关性，说明频繁观测并不等于有效纠偏。这些分析用于解释质量驱动自动标注、语义与几何监督 ACT、冻结基础策略的历史条件残差框架，并明确已有结果尚缺少的对照，而不把事后分析当作实验前已经证明的保证。本文给出可验证的充分条件，而不宣称语义、特定网络结构或动作误差降低自动保证任务成功。实机收益由独立任务评测确定，理论用于明确其可能机制与失效边界。

Index Terms—模仿学习，任务成功率，语义表示，几何监督，历史条件残差

I. 引言

遮挡交互操作要求机器人根据动态可见性、对象间关系及任务进展，持续决定合适的运动。模仿学习可以从示范中学习这些决策，但其常见优化目标是预测示范指令，而评测目标是整个任务是否完成。少量关键时刻的错误足以造成拨空、推离目标或未完成复原；大量普通运动帧上的准确预测可能掩盖这些错误。

目前实机已经观察到从基础 ACT 到语义表示和历史条件纠偏的逐步收益，详见第 VIII-B 节。研究不是仅凭直觉断言模块有效，而是从这些证据提出机制假设，再用理论明确条件并设计可反驳的对照。因此，本文的问题不是如何预先规定快慢网络，而是在有限示范与受限在线计算下，如何使学到的策略更可靠地依赖任务相关状态，并在执行过程中利用新证据修正偏差？我们遵循三个层次回答。第一，保留 RGB 可见细节，同时用语义分割提供对象和空间范围的显式表达，降低单纯从动作标签中发现相关视觉结构的负担。第二，用任务几何监督查询 token，要求策略内部表示保留可见程度、目标位置及工具关系，而不只满足全局动作拟合。第三，在基础动作块执行期间，用最新观测、当前计划和短期历史学习目标时间对齐的局部残差。

这条路径不依赖以下错误前提：更多输入一定有利，较低训练误差一定提高成功率，或者高频重规划本身一定优于持续执行。行为克隆的序列分布偏移已有明确分析 [1]；因果混淆研究也表明，额外观测及历史可能强化错误相关性 [2]。ACT 的时间集成本身包含频繁查询 [3]，不能视为完全没有反馈的基线。我们的分析需要解释的是表示、历史和反馈的使用方式，不是简单比较模块数量。

II. 相关理论与分析定位

性能差分恒等式把策略性能变化写为新策略访问分布下的优势累积，例如文献 [4] 的式 (1)；本文给出终端失败事件下的有限时域版本，不继承其优化算法的单调改进保证。DAgger 研究训练分布与策略访问分布之间的不一致 [1]。其中经典最坏情况误差累积结论采用相应分类损失与代价假设，不能直接把 ACT 的 L1 数值代入其公式。稳定性约束模仿学习进一步说明动力学的增量稳定性影响样本复杂度和轨迹偏差 [5]；本文没有学习或验证这样的全局稳定性证书。

本文后续的平方风险分解属于条件期望投影分析。它解释理想信息收益、表示损失及有限训练误差如何竞争，但本身不是样本复杂度改进定理。残差动作块修正已有相关研究 [6]，故本文不将一般实时残差形式声明为首创；需要验证的是低人工成本语义监督、几何查询表示与历史条件纠偏在目标任务上的组合价值。

III. 问题定义：视觉可评估的交互任务

A. 部分可观测的非线性交互

考虑机器人通过动作改变环境状态与可见性的交互任务。以 s_t 为物理隐状态， c_t 为离散交互模式， u_t 为一个或多个执行器的联合动作， $o_t = (I_t^{1:V}, q_t)$ 为 $V \geq 1$ 个视角及本体观测，可写为

$$\begin{aligned} s_{t+1} &= f_{c_t}(s_t, u_t, \xi_t), \\ c_{t+1} &= \chi(s_t, c_t, u_t, \xi_t), \\ I_t^v &= h_v(s_t, \nu_t), \quad v = 1, \dots, V. \end{aligned} \quad (1)$$

不预设已知动力学、固定接触模式或可直接观测的完整状态。遮挡使任务相关信息的可见性随交互改变，连续形变与模式切换使动力学可能非线性、非光滑。同一当前观察可能对应不同的隐藏运动状态。联合动作允许多个执行器通过共享环境耦合，而不将其限制为独立控制。

策略依据因果信息 $\mathcal{H}_t = (o_{0:t}, u_{0:t-1})$ 及任务条件 ℓ 生成指令。此处不指定输入模态的编码方式、记忆架构、阶段头或动作块分工。交互模式 c_t 与任务阶段也不相同：前者描述局部动力学，后者描述任务进展。多阶段任务可由多个条件及其时间关系表达，不要求预先固定阶段数。

B. 抽象任务函数与视觉评价

令 z_t 为理想的任务相关评价变量， ℓ 指定任务谓词、时间范围及可选的顺序约束。定义

$$\Psi_\ell = \Phi_\ell(z_{0:T}), \quad J_\ell(\pi) = \mathbb{E}_\pi[\Phi_\ell(z_{0:T})], \quad (2)$$

其中 $\Phi_\ell: \mathcal{Z}^{T+1} \rightarrow \{0, 1\}$ 是任务完成函数。不同任务改变 Φ_ℓ 的具体形式，而保持学习目标为提高 J_ℓ 。若任务只要求时限内某一时刻满足条件，则是上述定义的特例：

$$\Phi_\ell(z_{0:T}) = \mathbf{1}\{\exists t \leq T: g_{\ell,j}(z_t) \geq 0, \forall j\}. \quad (3)$$

需要顺序或保持要求时，改用相应的时序组合；不把一种具体操作的过程顺序强加给所有任务。谓词组合与裕量评价可参考时序逻辑的信号解释 [7]，但本方法不因此假设配备逻辑规划器。

称任务为视觉可评估，是指在声明的观测条件与评价域内，存在函数 $\mathcal{V}_\ell$ ，使理想视觉历史 $I_{0:T}^{*,1:V}$ 足以区分完成事件：

$$\Phi_\ell(z_{0:T}) = \mathcal{V}_\ell(I_{0:T}^{*,1:V}). \quad (4)$$

式(4)是适用条件，不是所有物理任务的事实。若成功与失败的两个物理过程产生不可区分的视觉历史，则任何纯视觉评价器均不能保证辨别，必须增加观测或限制评价域。实际带噪观测与学习到的评价器只近似满足该关系： $\hat{z}_{0:T} = \mathcal{E}(I_{0:T}^{1:V})$ ， $\hat{\Psi}_\ell = \Phi_\ell(\hat{z}_{0:T})$ 。观测不足时应允许评价未确定，而不是把缺失估计直接当作成功。

评价变量不必是策略的充分控制状态。即使完成条件能从当前图像确定，选择怎样运动仍可能需要速度、接触或历史信息。因此，视觉可评价完成、单帧可判别完成、单帧足以决策是三个不同命题。任务评价器也不必作为策略在线输入；它可以独立用于实验验证。

C. 表示误差与任务判别可靠性

在共同可评估域上，设 $\Phi_\ell(z) = \mathbf{1}\{\rho_\ell(z) \geq 0\}$ ，其中 z 简记整段评价变量，任务裕量满足 $|\rho_\ell(z) - \rho_\ell(\hat{z})| \leq L_\rho \|z - \hat{z}\|$ 。连续谓词裕量的有限次 min/max 组合是一个适用例子，但非连续谓词不自动满足该假设。对任意 $\gamma > 0$ ，

$$\mathbb{P}(\hat{\Psi}_\ell \neq \Psi_\ell) \leq \mathbb{P}(|\rho_\ell(z)| \leq \gamma) + \frac{L_\rho^2 \mathbb{E}\|z - \hat{z}\|^2}{\gamma^2}. \quad (5)$$

若真实裕量超过 γ 且误差小于 γ/L_ρ ，符号不变；联合界与 Markov 不等式给出此式。它表明判别错误取决于任务相关表示误差与边界附近的样本质量，而不只是整体视觉重建或像素分类精度。这是评价可靠性界，不是策略完成概率改进定理：可靠辨认状态仍须配合适当的动作与执行反馈。实际任务的谓词、阈值及评价域仅在实验章节实例化。

IV. 动作误差何时与任务完成一致

本节结论与推导路径。当参考专家可靠、部署状态被示范分布充分覆盖、动作误差能够泛化，且任务对动作偏差的敏感程度受控时，较小的动作风险能够支持更好的任务成功率下界，但不能保证两个策略的实际成功率按平均动作误差排序。本节先用有限时域性能差分恒等式，将失败概率差写成部署分布下的任务优势累积；再通过动作敏感性、分布覆盖及泛化条件，将其上界转换为可泛化动作误差的函数；随后用完整覆盖下的反例及状态相关敏感性，说明任务更依赖哪些状态上的预测准确性。现实中的有限数据、有限覆盖和有损观察难以满足理想保证，因此下一节研究语义及几何监督能否改善任务相关表示，再下一节研究更新观察和历史能否补足执行中的信息缺失。三者处理不同缺口，不把新增模块当作自动恢复所有理想条件的手段。

A. 任务目标与分析假设

任务在固定时域 T 内运行，成功事件为 $\Psi = 1$ ，失败包含超时和预先指定的违规条件。所有策略使用同一初始分布、环境转移和成功判据：

$$J(\pi) = \mathbb{P}_\pi(\Psi = 1), \quad F(\pi) = 1 - J(\pi). \quad (6)$$

为建立条件性结果，令 x_t 为共同的充分决策状态， $\pi(x_t)$ 为实际执行指令。必要的任务记忆、计划和时序状态可纳入 x_t ，使终端事件可由增广状态表达。这不声称单帧 RGB 满足 Markov 性。若只能使用有损观测或记忆编码，其信息缺失须另行计入，不能在应用理论时省略。

参考策略 π_E 假设为定义在所考察状态上的确定性专家。参考策略不必全局最优，但须有可接受的 $J(\pi_E)$ 。示范存在互相矛盾的动作模式时，动作条件均值不必仍是有效专家，此时不能把平方误差最优解直接代入下面的专家假设。令 D 为固定的正对角动作尺度矩阵，定义

$$e_\pi(x) = D^{-1}(\pi(x) - \pi_E(x)). \quad (7)$$

D 来自训练集，所有比较沿用相同尺度；归一化并不代表各关节具有相同任务代价。以下讨论执行时刻的动作误差，不默认全动作块各槽位平均误差等于实际执行误差。

令 $Q_t^E(x, a)$ 表示在 x 执行 a 后始终遵循专家的终端失败概率， $V_t^E(x) = Q_t^E(x, \pi_E(x))$ ， $A_t^E = Q_t^E - V_t^E$ 。 d_π^t 为执行策略 π 的状态分布， $\bar{d}_\pi$ 为 (t, x) 的均匀时间混合。由性能差分恒等式的有限时域形式，

$$F(\pi) - F(\pi_E) = \sum_{t=0}^{T-1} \mathbb{E}_{d_\pi^t} A_t^E(x, \pi(x)). \quad (8)$$

附录给出证明。等式的对象是闭环访问分布下、按任务后果衡量的误差，不是训练集的平均动作距离。

B. 覆盖、泛化与任务敏感性的共同作用

记专家分布平方动作风险为 $\epsilon_E = \mathbb{E}_{\bar{d}_E} \|e_\pi\|^2$ 。假设部署分布被专家分布控制，且动作偏离引起的任务风险有界：

$$\bar{d}_\pi \ll \bar{d}_E, \quad \frac{d\bar{d}_\pi}{d\bar{d}_E} \leq C, \quad (9)$$

$$A_t^E(x, a) \leq L \|D^{-1}(a - \pi_E(x))\|. \quad (10)$$

C 表示覆盖程度而非样本条数， L 表示任务对动作偏差的敏感程度。覆盖假设要求相关状态及其频率，不只是物体初始位置网格齐全。完整连续历史包含确定性动作时，两策略的历史分布甚至可能互相奇异；因此不能未经验证就在全历史空间假定有限 C 。采用低维状态近似虽方便，也必须检查其充分性。接触不连续、硬阈值成功事件或悬崖式失败附近，有限且有用的 L 也可能不存在。

命题 1 (动作风险到成功率的条件性界)：若式(9)–(10)成立，则

$$J(\pi) \geq J(\pi_E) - TL\sqrt{C\epsilon_E}. \quad (11)$$

若以至少 $1 - \delta$ 的概率有 $\epsilon_E \leq \hat{\epsilon}_E + g_\delta$ ，则同概率下

$$J(\pi) \geq J(\pi_E) - TL\sqrt{C(\hat{\epsilon}_E + g_\delta)}. \quad (12)$$

下界可截断到零。

由式(8)、Cauchy–Schwarz 及密度比界立即得到，详见附录。式(12)中的 g_δ 不可忽略：训练误差下降但泛化间隙扩大，不给出更强保证。若仅有同轨迹相邻帧上的随机划分，不能把帧数当作独立样本数。该界也可能很松，本文不以未知的 C, L 生成数值成功率预测。

覆盖不全时，设 $\bar{d}_\pi = (1 - \kappa)d_{\text{cov}} + \kappa d_{\text{out}}$ ，其中 $d_{\text{cov}} \leq C\bar{d}_E$ ，式(10)只在覆盖部分成立。利用终端失败优势至多为 1，

$$F(\pi) - F(\pi_E) \leq T[(1 - \kappa)L\sqrt{C\epsilon_E} + \kappa]. \quad (13)$$

覆盖域内误差趋零仍不能消除域外项。这里 κ 是未覆盖的平均访问质量，不是每条轨迹必然失败概率，故保留保守的 T 因子。更换策略也会改变 C 和 κ 。

C. 更小误差不等于更高成功率

下界改善不等于两个真实成功率的单调排序。即使 $T = 1$ 且训练测试分布完全一致，结论仍不成立。设两个状态等概率出现，专家均输出零，状态 1 的失败概率为 $\min(1, 100a^2)$ ，状态 2 任意动作均成功。策略 P 分别输出 $(0.1, 0)$ ，策略 Q 输出 $(0, 0.2)$ ，则

$$\epsilon_P = 0.005 < 0.020 = \epsilon_Q, \quad J(P) = 0.5 < 1 = J(Q). \quad (14)$$

这不是覆盖缺失，而是误差发生位置及后果不同。在实际任务中，工具接触前后的少量误差可能比自由运动误差重要得多。

严格的策略改进条件应相对于当前基线 π_0 的任务优势描述：

$$\sum_t \mathbb{E}_{d_{\pi_1}} A_t^{\pi_0}(x, \pi_1(x)) < 0 \implies J(\pi_1) > J(\pi_0). \quad (15)$$

普通 L1/MSE 没有直接监督该条件。只有额外建立代理损失与任务优势的关系，并控制访问分布变化，才可谈一致性。本文的合理主张是：降低可泛化的、任务相关的执行误差，是提高成功率的支持路径，而非充分的模型排名规则。

D. 从理想保证到实际缺口

前面的保证指出三个现实困难。有限数据与表征学习困难：即使某类控制关系在示范中出现，有限样本也未必足以使模型从高维外观中发现并保留该关系；低训练误差不等于低泛化误差。覆盖不全：外观组合缺失与控制状态缺失不同，前者可能通过不变先验缓解，后者不能仅靠重新编码已知图像补全。观察与执行不同步：生成动作时的观察可能不充分或已经过时，即使图像表示准确，也不能表达尚未观察到的后续变化。这些缺口分别引出表示监督与增量反馈，但尚未解释为何应强调某些语义关系。

为连接关键状态与表示选择，将式(10)的统一常数细化为非负的状态相关敏感性 $w(t, x)$ ：

$$A_t^E(x, a) \leq w(t, x) \|D^{-1}(a - \pi_E(x))\|. \quad (16)$$

定义 $\epsilon_{E, w} = \mathbb{E}_{\bar{d}_E}[w \|e_\pi\|^2]$ ， $\bar{w}_\pi = \mathbb{E}_{\bar{d}_\pi} w$ ，假设这些量有限。由加权 Cauchy-Schwarz 及同一覆盖条件，

$$\begin{aligned} F(\pi) - F(\pi_E) &\leq T \mathbb{E}_{\bar{d}_\pi}[w \|e_\pi\|] \\ &\leq T \sqrt{\bar{w}_\pi C \epsilon_{E, w}}. \end{aligned} \quad (17)$$

取 $w \equiv L$ 即回到式(11)。这说明高敏感状态上的误差对该保证影响更大，而不只是这些状态应在叙述上被称为关键。这里 w 是分析中的任务敏感性，不是现有训练的权重，更不是 SAM2 标签质量分数；关键事件标记也不自动等于已估计的 w 。

由此得到下一节的明确问题：如果高敏感状态下需要区分控制关系，能够由可靠语义几何表示，辅助监督能否减少这些状态上的表示与动作误差？关系在视觉上显著并不足够，还必须对动作有用。若关键差异来自视觉不能区分的隐变量，或来自完全未见的控制规律，语义表示并不能解决它。式(17)提供需要改善的风险对象，而不是直接证明语义或 QToken 已经改善了它。

V. 语义与查询表示为何可能有效

本节结论与推导路径。上一节把困难定位为有限数据下的任务相关误差，而非笼统的像素信息不足。由已有 RGB 确定的语义图不会增加原始观测信息，但外部分割监督与几何查询监督可以提供任务相关的归纳偏置，在有限数据下减少表示丢失的信息和实际动作读出误差。收益要求所选几何关系与控制有关、估计足够可靠，且策略能够利用该表示，新增编码与监督的代价没有抵消这些收益。本节先用条件期望将平方动作风险分解为不可约风险、表示损失与读出误差，再由几何的近似充分性及 Lipschitz 条件，推导几何估计误差对动作风险的条件性上界，并在同一任务敏感性加权分布下将其连接回上一节的任务界，最后分析伪标签与不可见关系如何限制该结论。因此，实验须区分几何可读出、动作实际使用该表示，以及闭环任务表现改善这三个层次。

A. 增加原始观测与加入语义先验不同

在固定评价分布 μ 上，令 Y 为相同目标执行时刻的归一化示范动作，所有变量二阶可积，所有模型参数视为训练后固定。若 X 为已有输入， I 为新增视角或更新的图像，则理想平方预测风险满足

$$R^*(X) - R^*(X, I) = \mathbb{E} \|\mathbb{E}[Y | X, I] - \mathbb{E}[Y | X]\|^2 \geq 0. \quad (18)$$

额外信息改变条件动作均值时才严格改善；实际学习误差可能抵消该收益。

若分割图 $S = g(I)$ 由已有 RGB 确定，固定分割器后

$$\sigma(I, S) = \sigma(I), \quad R^*(I, S) = R^*(I). \quad (19)$$

所以语义不是对原始 RGB 增加新的测量信息。外部分割标签及预训练引入了额外的学习先验，将对象身份与空间范围直接编码，可能使有限数据模型更易学习合适映射。这也说明只比示范条数不足以衡量公平性：额外标签、人工审核和预训练均应披露。

令 $\mathcal{O}$ 为共同允许的输入信息， Z 为实际表示， $m_{\mathcal{O}} = \mathbb{E}[Y | \mathcal{O}]$ ， $m_Z = \mathbb{E}[Y | Z]$ 。条件期望正交性给出

$$\begin{aligned} R(p_Z) &= R(m_{\mathcal{O}}) + a_Z + e_Z, \\ a_Z &= \mathbb{E} \|m_{\mathcal{O}} - m_Z\|^2, \quad e_Z = \mathbb{E} \|p_Z - m_Z\|^2. \end{aligned} \quad (20)$$

语义的收益必须落在表示信息损失 a_Z 和实际读出误差 e_Z 的净下降上。增加 token 与共享编码器也可能增加优化困难，不能只看输入更直观就预设收益。

B. 归纳偏置能处理哪类覆盖缺失

将控制相关变量记为 (G, C) ，无关外观记为 N 。若不同环境均满足

$$\mathbb{E}[Y | G, C, N] = f(G, C), \quad (21)$$

且变化只发生于 N ，则同一几何决策函数无需重新学习每种纹理。例如目标和工具关系不变但背景颜色改变，可靠语义可以减少对外观偶然相关性的依赖。这要求语义估计器本身对该变化也可靠，且相关几何和控制条件已有覆盖。它不解决从未见过的工具接触模式、物体动力学、目标完全消失后的任意恢复。

式(21)是需验证的假设，不是分割标签自动获得的因果结论。历史中上一动作、夹爪状态等也可能成为错误捷径[2]。共享 RGB 路径并未被强制成为不变表示；应通过外观干预和几何保持对照检验，不能仅用分割 IoU 解释策略的分布外表现。

C. 几何监督 QToken 的条件性作用

令 G 为任务几何, C 为必要控制上下文。假设存在关于几何为 L_G -Lipschitz 的 f , 使

$$\mathbb{E}\|m_{\mathcal{O}} - f(G, C)\|^2 \leq \epsilon_{\text{suf}}. \quad (22)$$

ϵ_{suf} 容纳几何之外的姿态、接触、历史等因素。从查询表示 Z_Q 可读出 $\hat{G} = d(Z_Q)$, 并可访问 C , 设 $\epsilon_G = \mathbb{E}\|\hat{G} - G\|^2$.

命题 2 (几何表示的误差界): 实际动作读出误差记为 e_Q , 则

$$R(p_Q) - R(m_{\mathcal{O}}) \leq (\sqrt{\epsilon_{\text{suf}}} + L_G \sqrt{\epsilon_G})^2 + e_Q. \quad (23)$$

证明利用 $f(\hat{G}, C)$ 作为 Z_Q 的候选动作读出, 见附录。若基线的超额风险 $a_0 + e_0$ 大于右侧, 则有严格平方风险改善。但基线表示信息损失的下界通常难以估计; 一个较差的探针误差不是其下界。该命题给出可能的充分条件, 不证明加入辅助监督后必然满足这些条件。

语义图给出对象区域; 几何监督 query 进一步要求指定关系能够被编码和读出。具体监督关系由任务选择, 而不要求一种固定的几何量或完整阶段标签。辅助 loss 给 query 及其关联视觉特征提供梯度, 但不指定 attention map, 也不保证动作 decoder 实际利用了它。因此需同时检查几何精度、query 消融后的动作变化和闭环成功率。不能把当前 QToken 写成已经具备阶段切换或停止判定的模型。

D. 把几何表示界接回任务性能界

仅证明平均几何误差变小, 尚未回答上一节提出的关键状态问题。令 $Z_w = \mathbb{E}_{\tilde{d}_E} w > 0$, 定义归一化的敏感性加权分布 $d\mu_w = (w/Z_w)dd_E$ 。本节的投影分解与几何界可统一在 μ_w 下重新推导, 但条件均值及所有误差也必须按该分布重新定义, 不能只给最终公式乘一个权重。以角标 w 表示这些量, 记

$$B_w = R_w^* + (\sqrt{\epsilon_{\text{suf}, w}} + L_G \sqrt{\epsilon_{G, w}})^2 + e_{Q, w}. \quad (24)$$

若监督目标确为前节参考专家在同一决策状态、同一执行时刻的动作, 则 $\epsilon_{E, w} = Z_w R_w(p_Q) \leq Z_w B_w$, 从而

$$J(\pi_Q) \geq J(\pi_E) - T \sqrt{\bar{w} \pi_Q C Z_w B_w}. \quad (25)$$

R_w^* 表示允许观察下仍然不可约的预测风险。示范动作含模式歧义或目标时间错位时, 不能不经校验就把监督风险代入此式。

这给出了层层连接的充分条件: 任务敏感的控制关系在所选几何中近似充分, 其估计与读出误差足够小, 且部署覆盖受控, 才有更紧任务保证的可能。严格改善几何表示的动作风险, 要求加权几何界的超额部分小于基线的加权超额风险; 仅比较两个上界大小仍不是实际策略排序证明。新增语义不被宣称自动降低 C 、 w 或未覆盖质量 κ , 而是在这些条件成立的范围内改善表示相关风险。

因此, 关键状态与 QToken 之间不是直接等号, 而是任务敏感性提出需要区分的关系, 几何监督尝试让这些关系被保留, 动作读出再将其转为更准确的决策。监督了不相关关系, 或关系虽准确却未被动作使用, 都不能完成这一链条。

E. 伪标签、不确定性与不可见关系

令 $\tilde{G}$ 为伪标签。无偏假设不是必需的, 但真值误差满足

$$\epsilon_G \leq 2\mathbb{E}\|\hat{G} - \tilde{G}\|^2 + 2\mathbb{E}\|\tilde{G} - G\|^2. \quad (26)$$

仅减小伪标签拟合误差不能保证第二项小; 稳定地把机械臂误分为目标可能同时具有高时间一致性和高系统偏差。质量分数只能作为诊断和相对权重, 须通过独立人工抽样验证。

对标量几何和质量权重 $W \geq 0$, 加权平方目标的最优读数为

$$d_W(z) = \frac{\mathbb{E}[W\tilde{G} \mid Z = z]}{\mathbb{E}[W \mid Z = z]}, \quad \mathbb{E}[W \mid Z = z] > 0. \quad (27)$$

它不自动等于 $\mathbb{E}[G \mid Z = z]$ 。把困难状态长期降权可能降低其有效覆盖。实际 Smooth L1 的最优解也不直接等于式(27)。对不可见关系, 几何界只在有效域解释; 目标不可见时面积零仍有效, 但目标与工具距离未定义, 不能伪造零距离监督。不可见域的策略风险必须单独报告, 不能在整体成功率论证中删掉。

F. 表示改善之后仍然缺少什么

即使上述几何误差和读出误差很小, 固定观察下的 R_w^* 仍可能为正: 任务相关动态不能总由当前静态几何辨别, 执行期间的新变化也不包含在生成原计划的旧观察中。因此, 单纯继续强化同一帧的语义监督不能消除全部残余误差。下一节转向扩大可用的因果信息并学习其对当前计划的修正: 更新观察响应执行中变化, 历史帮助区分动态歧义。这不是取代本节的表示学习, 而是针对它没有解决的信息与时序缺口。

VI. 新观测如何转化为有效纠偏

本节结论与推导路径。上一节改善已有观察的任务相关表示, 但不能恢复旧观察没有记录的新变化, 也不能保证单帧几何足以区分动态状态。本节针对这一剩余缺口引入增量信息。新观测只有帮助预测当前计划的误差, 并产生方向合适、幅度不过大的修正时, 才会降低动作风险; 历史只有提供当前信息之外的可预测残差, 且收益超过编码与拟合代价时, 才会进一步改善纠偏。更高观测频率或采用 GRU 本身均不构成改进保证。本节先以条件期望投影分解当前信息、历史与实际残差预测器的风险, 再将实际收益写成误差与修正的对齐项减去修正能量; 随后通过时间集成的偏差与协方差分解, 说明频繁查询为何仍可能受到旧计划偏差影响, 最后给出动作风险改善转化为任务成功率改善所需的更强任务方向条件。相应实验应控制基础策略与实际延迟, 并通过历史对照及修正方向诊断检验收益来源。

本节先在固定评价分布上分析实际动作修正。若需强调上一节的高敏感状态, 可在同一 μ_w 下重新定义全部条件期望与风险; 在覆盖和参考动作对齐等条件下, 所得动作风险再进入式(17)。这保持了共同的任务目标, 但不将离线回放分布直接当作纠偏后的闭环分布。

A. 历史条件残差的可利用信息

固定评价分布及目标时刻, 令 B 为归一化基础动作, $E = Y - B$ 。 $\mathcal{F}_c$ 包含最新观察、当前关节及计划上下文, $\mathcal{F}_h \supseteq \mathcal{F}_c$ 再包含因果历史。定义 $m_c = \mathbb{E}[E \mid \mathcal{F}_c]$,

$m_h = \mathbb{E}[E | \mathcal{F}_h]$ 。理想历史残差比理想当前帧残差减少的风险为

$$\Delta_h = \mathbb{E}\|m_h - m_c\|^2. \quad (28)$$

同一当前画面但不同的接近速度、接触前后状态或过去遮挡记录，若需要不同修正， Δ_h 可能为正；重复帧或无关历史则不保证收益。

令 GRU 与其他输入产生信息 $U \subseteq \mathcal{F}_h$ ，实际残差 r 为 U 可测， $m_U = \mathbb{E}[E | U]$ 。

命题 3 (历史编码与残差收益): 设 $\epsilon_{\text{enc}} = \mathbb{E}\|m_h - m_U\|^2$ ， $\epsilon_{\text{fit}} = \mathbb{E}\|r - m_U\|^2$ ，则

$$R(B) - R(B + r) = \mathbb{E}\|m_h\|^2 - \epsilon_{\text{enc}} - \epsilon_{\text{fit}}, \quad (29)$$

$$R(B + r) - R(B + m_c) = \epsilon_{\text{enc}} + \epsilon_{\text{fit}} - \Delta_h. \quad (30)$$

历史中的可预测残差必须超过编码和拟合代价才能改善。GRU 是实现选择；这里不存在 GRU 必然优于 LSTM 或 Transformer 的结论。有界残差与正则可能牺牲拟合最优性，其影响包含在 ϵ_{fit} 中。最新观测的收益也可用式(18)分析，但必须与相同目标时间的旧信息比较。对任意实际残差，还可直接检验

$$R(B) - R(B + r) = 2\mathbb{E}\langle E, r \rangle - \mathbb{E}\|r\|^2. \quad (31)$$

修正方向与误差不一致，或修正过大，均可能恶化动作风险。

B. 为何频繁 ACT 与时间集成可能效果不好

ACT 时间集成聚合同一执行时刻的多次预测 [3]。令 $\hat{u}_{\tau|k}$ 为第 k 次查询对 τ 的预测， $w_k \geq 0$ ， $\sum_k w_k = 1$ ，则

$$u_{\tau}^{\text{TE}} = \sum_k w_k \hat{u}_{\tau|k}. \quad (32)$$

它确实使用新观测，因此不能把残差优势归因于基线没有实时信息。相对同一参考动作 u_{τ}^* ，令预测误差为 $b_k + \xi_k$ ， $\mathbb{E}\xi_k = 0$ 。对固定权重，

$$\mathbb{E}\|u_{\tau}^{\text{TE}} - u_{\tau}^*\|^2 = \left\| \sum_k w_k b_k \right\|^2 + \sum_{k,l} w_k w_l \text{tr Cov}(\xi_k, \xi_l). \quad (33)$$

相关误差的方差降低有限，且旧预测在接触变化后可能带有系统偏差。若旧预测为 a 、新预测与当前正确目标均为 b ，旧预测总权重为 α ，则时间集成误差为

$$\|u^{\text{TE}} - b\|^2 = \alpha^2 \|a - b\|^2. \quad (34)$$

此外，不同接触方案的平均动作未必对应有效接触路径。但不能据此宣称平均总会变差：平方范数凸性保证

$$\left\| \sum_k w_k e_k \right\|^2 \leq \sum_k w_k \|e_k\|^2, \quad (35)$$

它只是未保证优于最新或最好的单次预测，也未保证任务成功。

当前仓库的时间集成权重以最旧预测为索引 0， $w_i \propto \exp(-mi)$ ；正 m 更偏向旧预测， $m = 0$ 为均匀平均。该实现特征不能替代实机配置核查：必须知道部署是否启用 TE、实际系数、查询频率和结果年龄，才可解释某次失败。用户观察到的较差表现与式(34)相容，但尚非其因果证据。

C. 残差的区别与任务改进边界

残差显式条件于正在执行的计划，学习该计划在新证据下应改多少；它不要求每次独立重选完整动作模式。时间集成保留的是多次预测的加权记忆，不等于学习了观察历史的状态估计。若直接预测器具有同样的信息、函数能力、训练目标及算力， $B + r$ 与直接动作预测可互相参数化，不存在表达能力上的普遍优越性。冻结基础策略、零初始化、有界局部更新和匹配时序的监督是归纳偏置，不是无条件改进保证。残差同样可能受到时延、错误记忆和覆盖缺失影响。

对任务成功率，设 Q_t^B 是基础控制器的失败代价，在归一化动作 b 周围二阶光滑，Hessian 上界为 M 。则

$$A_t^B(x, b + r) \leq \nabla_b Q_t^B(x, b)^{\top} r + \frac{M}{2} \|r\|^2. \quad (36)$$

若右侧在修正后控制器的访问分布上跨时刻求期望严格为负，式(15)给出成功率严格提升。这要求修正沿任务风险下降方向，比式(31)更强。当前监督残差没有学习 Q^B ，不能声称已验证此条件；小动作误差与局部任务风险方向一致的接触模式、覆盖及安全裕量需要实验支撑。限幅也不能独自保证该条件。

训练只含成功示范时，纠偏器学习的是示范观测下基础预测的残差。模型自主偏离后，同时间索引的示范指令未必仍是合适恢复动作；没有反事实恢复标签就不能承诺大范围恢复。离线回放检验式(31)，闭环测试另行检验修正后分布及任务后果，两者必须分开。

VII. 理论指向的实现

A. 先控制标注噪声，再学习策略

方法将标签质量、表示监督和在线反馈分开处理。首先由类别定义和少量代表帧生成离散框/点 JSON 提示，渲染后人工审核；SAM2 [8] 传播种子视频。通过时间 IoU、面积跳变、质心跳变、连通域异常及可用时的双向一致性定位待重试片段，少量人工复核后训练分视角 YOLO 提示器，再扩展到全数据集并迭代修复。这些诊断分数不是校准概率，也不能发现所有一致性错误。未来帧仅用于离线标注，不能进入在线反馈。

数据按 episode 划分。作为全流程未见测试的片段不得参与提示器、分割器、策略或阈值的拟合；不满足这一条件的旧结果须披露实际已见范围。质量分数影响离线重试和有效样本选择，并用于几何监督的相对加权。当前 U-Net 的类别加权 CE 与前景 Dice 不应被写成已默认逐帧质量加权。分割质量需由独立人工审计支持，而非仅比较模型与其自身伪标签。

B. 语义输入与几何监督查询

为各视角单独训练并冻结轻量 U-Net；当前 front 含背景共 7 类，side 含背景共 5 类，保留相应的类别差异。完整视野缩放到 480×270 ，概率 $P^v(c, u)$ 通过固定调色板 $p_c \in [0, 1]^3$ 转为

$$S^v(u) = \sum_c P^v(c, u) p_c. \quad (37)$$

这是 soft 颜色图，不是 argmax；多类别到三通道通常不可逆。每路 RGB 及对应语义图分别通过同一个 ResNet18 和投影后进入 ACT，双视角共四路视觉 token，单视角两路，使用原 ACT 位置编码，不加入 camera/modality

embedding。保留 RGB 是为了避免几何类别丢弃未标注的姿态与接触线索；共享骨干是实现选择，而不是理论结论。

三个 512 维可学习 query 与视觉、关节等 token 共同进入 encoder，其输出由辅助头预测 front 几何：

$$\begin{aligned} G_1 &= |M_O|/(WH_I), \\ G_2 &= \|c_O - c_R\|/\sqrt{(W-1)^2 + (H_I-1)^2}, \\ G_3 &= \bar{c}_O - \bar{e}_{T,L} \in \mathbb{R}^2. \end{aligned} \quad (38)$$

c_O, c_R 为目标与区域质心；tool mask 在归一化图像平面上做 PCA 主轴拟合，选择两个投影极值端点中横坐标更小的 $\bar{e}_{T,L}$ 。该端点是图像约定，不自动等同于真实接触端。

目标不可见时面积零仍监督；关系成员不可见时屏蔽对应关系监督。令 v_{bi} 表示几何组有效， q_{bi} 为相关类别质量最小值， $w_{bic} = v_{bi} \min(q_{bi}/0.95, 1)$ 。当前几何 loss 按组计算

$$L_G = \frac{1}{3} \sum_{i=1}^3 \frac{\sum_{b,c} w_{bic} \ell_{0.01}(\hat{G}_{bic} - \tilde{G}_{bic})}{\max(1, \sum_{b,c} w_{bic})}. \quad (39)$$

ℓ_β 为 Smooth L1；三组维度为 1、1、2。归一化后权重主要改变样本的相对贡献，全组同倍降权可能被分母抵消。ACT 优化 $L_{L1} + \lambda_{KL} L_{KL} + \lambda_G L_G$ ，当前 $\lambda_G = 1$ ；几何 loss 不更新冻结分割器。动作 decoder 可读取完整 encoder 上下文，包括 query 隐藏状态。当前没有额外阶段分类、阶段切换或停止头。区域质心距离也不等价于完整包含率；不能据此声称模型显式判定任务完成。

C. 冻结基础策略的历史条件纠缠

基础策略训练后冻结，残差分支每次只编码新到达的双视角 RGB，完整视野缩放为 320×180 ，冻结骨干后池化为每视角 $2 \times 3 \times 512$ 特征；窗口内旧视觉使用缓存，不重复分割或编码。上下文包括实际 follower 关节、因果速度估计、上一发送指令、未来基础动作及相对关节差、有效槽位、计划年龄和观察间隔。

三个实现分支分别为：A 使用 RGB ACT 与最新 RGB；B 使用语义 ACT，并在快更新时额外提取双视角分割描述；C 使用 QToken ACT，将当前生效基础计划的 query 隐藏状态与最新 RGB 结合。C 的 query 不是每次快更新重新计算，不能写为实时几何测量。A/B/C 的基础策略不同，跨分支收益不能直接归因于 GRU 输入差异。

最近 8 条因果记录经 128 维投影与单层 hidden128 的 GRU 编码；每次从窗口起点的零隐藏状态重算，5Hz 下跨度约 1.4 秒。断流或重置清空历史。快头输出

$$\delta a_j = \beta \odot \tanh([W_r h + c_r]_j), \quad \hat{a}_j = b_j + \delta a_j. \quad (40)$$

输出层零初始化，每维限幅由训练集基础误差 P95 设定，当前裁剪到 $[0.05, 5]$ 原生命单位，换平台需核对单位。监督使用 leader 示范指令、follower 观测，不混同此前 follower-delta 实验。当前损失为有效槽位上标准差缩放后的 Smooth L1 ($\beta = 0.1$) 及 10^{-3} 的平方残差正则；AdamW 学习率 10^{-4} ，batch128，最多 50 轮，验证 8 轮不改善早停，以验证缩放 MAE 选择 checkpoint。理论平方风险另外计算，不从该混合训练 loss 直接推断成功率。

D. 目标槽位对齐与失效处理

当前 30Hz 控制，基础动作块 60 步、每 30 步重规划；快更新每 6 帧一次，目标延迟 3 帧，输出 9 步残差。第 6 帧观察对应第 9 至 17 帧，第 12 帧观察对应第 15 至 23 帧，相邻修正区间重叠 3 帧；及时使用首槽的端到端预算为 100ms。所有结果绑定 plan ID 和目标执行槽位，只替换尚未执行的对应残差，始终加到原基础动作而非累加旧修正。计划切换清空旧计划残差，迟到丢弃过期前缀而不移动目标时间。

最大结果观察年龄 0.15 秒、残差年龄上限 0.4 秒等规则须以实机部署配置核对。无有效残差时回退有效基础动作，基础动作也过期时使用已验证的硬件安全处理，不得无限复用最后指令。实时评测应包含图像获取、预处理、编码、队列、GRU 及发布延迟，而非仅报告神经网络 kernel 耗时。

VIII. 实验协议与验证重点

A. 双臂任务的完成判据

评价首先在参考视角定义完整目标区域足迹 R^* ，并令 Ω 为该参考视角的整幅图像域。令 O_t^* 为目标完整投影， C_t 为遮挡布料投影。当目标完整可评估且 $|O_t^*| > 0$ 时，定义

$$p_{in}(t) = \mathbf{1}\{O_t^* \subseteq R^*\}, \quad (41)$$

$$a_C(t) = |C_t \cap \Omega|/|\Omega|, \quad (42)$$

$$p_{store}(t) = \mathbf{1}\{a_C(t) \geq \theta_C\}. \quad (43)$$

R^* 不是当前可见 region 类别 mask：互斥分割使 object 与可见 region 不重叠，直接求交会误判。固定目标区域可由无遮挡参考帧独立标注；相机或区域移动时须重新估计。仅有局部可见的目标 mask 也不能替代 O_t^* 来证明整个物体已进入区域。

当前布料复原不会重新遮挡目标物体，复原指标是布料在画面中的面积占比，不是目标被遮挡比例，也不是默认裁剪桌面 ROI 后的占比。按这一要求，任务在规定时间内满足下式即可完成：

$$\Phi_\ell(z_{0:T}) = \mathbf{1}\{\exists t \leq T : p_{in}(t) = 1 \wedge p_{store}(t) = 1\}. \quad (44)$$

两项必须在同一完成时刻成立：不能仅凭初始布料面积较大，也不能凭曾经入区但随后又移出的记录判成功。若协议另要求连续 d_C 帧确认，则在同一窗口内检验这两个谓词，并要求窗口终点不超过 T ；未指定持续时间时不默认添加这一要求。当前 T, θ_C, d_C 的数值待统一评测协议确定，不从历史其他实验的 50%、80% 或 95% 阈值推定。

若最终物体与目标区域均可清晰评价，式(44)的两个谓词可以由同一参考帧判定，不必依赖假设的最终目标遮挡。执行中被机械臂临时遮挡仍可能导致评价证据不足，但不能把这种局部情况混同于任务要求布料最后重新遮住物体。暴露、分离、推动和复原是有助于解释行为的过程事件；并非所有任务都必须采用同一组过程标签，更不要在问题定义中指定阶段头。

B. 已有结果与需要解释的机制

研究首先由实机现象驱动。表 I 记录用户目前提供的近似成功率，而非本稿重新汇总的最终统计结果。用户已确认各组使用相同的策略示范数据与训练轮次，因此该结果是在一致的数据与训练预算下比较不同设计，而不是更

TABLE I
初步实验结果；次数、视角及配对条件待逐项核对

方法描述	近似成功率
基础 ACT	50%
ACT + MLP 残差	60%
ACT + GRU 残差	70%
语义输入策略 (无 QToken)	70%
双视角语义 + QToken	80%
语义 + QToken + QTokenGRU	87%

多动作示范带来的收益。这里语义输入不是语义替代全部 RGB，具体视觉配置以 checkpoint 为准。不能假设各行具有相同分母、训练随机性或相同基础策略，也不能将约 10 个百分点的差异直接解释为显著的因果效应。

这些结果提出三项可检验解释。表示解释：语义预训练将对象区域的先验显式提供给策略，几何监督进一步减少目标关系被编码丢失的风险。应检查这种收益是否集中于拨空减少、有效接触和完整入区，并排除单纯增加视角或 token 容量。反馈解释：当前帧残差能根据最新证据修正当前计划，因此无需每次重选完整动作块。应比较相同基础 checkpoint 下的无残差、MLP 残差与频繁 ACT 查询。历史解释：GRU 可借助过去的观测和动作上下文区分当前画面中的运动歧义。应与历史置乱、仅最新帧及同历史的非循环模型比较，而不把 GRU 对 MLP 的所有收益都归于记忆架构。

从约 80% 到 87% 还提示几何表示与纠缠可能互补，但证明完整系统更好不等于证明模块之间存在协同效应。后续优先以相同平台、视角和预算下的 RGB/语义 QToken 与无残差/GRU 组成匹配的 2×2 对照，检验收益是否仍然存在；未完成这一控制前不报告加性分解或协同结论。理论的职责是把上述解释转为明确条件与反证实验，不是用已经观察到的收益反推所有假设必然成立。

C. 已知任务设置与位置划分

当前任务为双臂协作暴露目标、将目标完全拨入目标区域、再恢复布料画面占比，使用三个物体类别和一种布料颜色。以用户提供的 (r, c) 为网格索引，不将其当作米制坐标，训练初始位置为

$$\mathcal{P}_{tr} = \{(0, 0), (0, 3), (1, 1), (1, 2), (2, 0), (2, 3)\}. \quad (45)$$

测试覆盖 $\mathcal{P}_{test} = \{0, 1, 2\} \times \{0, 1, 2, 3\}$ ，其中六个未采集位置为

$$\mathcal{P}_{new} = \{(0, 1), (0, 2), (1, 0), (1, 3), (2, 1), (2, 2)\}. \quad (46)$$

每轮三个物体各测 12 格，共 36 个条件单元；其是否各测一次、各方法实际重复次数和有效样本数尚待日志确认。应分别报告 18 个已采集位置条件和 18 个未采集位置条件的结果，再报告各物体和总体成功率。

该设计支持同一工作区内未采集初始位置的泛化研究，不是未见物体类别、布料颜色或任意动力学的泛化验证。若网格等距且几何布局一致，新位置位于所列四角形成的范围内，更适合称为工作区内位置泛化，而不是空间外推。即使初始化未见，示范运动也可能经过这些位置，因此还不能称为整个状态空间严格未见。未来若使用另一平台，独立定义该平台的 Φ_ℓ ，保留通用输入与纠缠接口，不要复制相同颜色或网格。

D. 从现有结果出发的最小补充验证

首先固定所有方法的时限、包含判据、覆盖域、覆盖阈值、观察年龄和试验配对，从日志补齐成功次数与置信区间，按物体和新旧位置分层；其次在相同基础 checkpoint 下比较无残差、MLP 与 GRU，进行历史置乱、最新观察延迟和动作误差方向诊断，以定位记忆与反馈收益；随后固定双视角语义基线，对照无 query、无几何监督的等量 query 与有监督 query，同时检查几何精度、动作依赖和拨空/接触/完整入区等事件，排除视角和容量变化；最后用匹配的 2×2 表示与 GRU 对照验证互补性，仅在主结论稳定后扩展扰动、颜色、数据量或新平台实验。成功评价采用独立人工复核或独立冻结评估器，防止使用策略自身分割把同一种错误同时计为正确决策与成功。所有实验围绕表 I 的机制解释展开，而不是再同时增加新的阶段头、融合器和控制器。

IX. 讨论

语义先验主要减少无关外观引起的学习困难，不能凭空补足未见的接触动力学或失败恢复示范。几何量不是完整任务状态，记忆也可能学习错误的历史相关性。本文既 not 将监督残差称为离线强化学习，也不把残差限幅称为稳定性约束。性能差分、条件期望分解等是已有理论工具；本文的推导是针对当前系统的条件性分析，不是把这些工具本身包装为新的理论贡献。最终贡献应由方法、数据效率、跨任务闭环收益和机制验证共同支撑。

Appendix A 主要推导

A. 有限时域性能差分

令 $V_T^E(x_T) = \mathbf{1}\{\Psi = 0\}$ ，状态包含评价终端事件所需的记录。Bellman 关系为 $Q_t^E(x, a) = \mathbb{E}[V_{t+1}^E(x_{t+1}) | x, a]$ 。因此沿 π 的轨迹，

$$\begin{aligned} \sum_t \mathbb{E}_\pi A_t^E(x_t, \pi(x_t)) &= \sum_t \mathbb{E}_\pi [V_{t+1}^E(x_{t+1}) - V_t^E(x_t)] \\ &= \mathbb{E}_\pi V_T^E - \mathbb{E}_{x_0} V_0^E \\ &= F(\pi) - F(\pi_E). \end{aligned}$$

这里以终端状态的指示变量定义价值；环境随机性由条件期望积分。相同初始分布是最后一步成立的必要条件。随后

$$\begin{aligned} F(\pi) - F(\pi_E) &\leq TL \mathbb{E}_{\bar{d}_\pi} \|e_\pi\| \\ &\leq TL \sqrt{\mathbb{E}_{\bar{d}_\pi} \|e_\pi\|^2} \\ &\leq TL \sqrt{C\epsilon_E}, \end{aligned}$$

得到式(11)。在覆盖混合的两部分分别使用此论证和 $A_t^E \leq 1$ ，得到式(13)。

B. 何时训练误差可以进入该界

例如，预先固定的有限策略集合含 M_Π 个候选，每条专家轨迹的平均平方损失位于 $[0, B_\ell]$ ， n 条轨迹独立采样。Hoeffding 不等式及联合界给出

$$g_\delta = B_\ell \sqrt{\frac{\log(M_\Pi/\delta)}{2n}}. \quad (47)$$

此时可对数据选择的候选使用式(12)。这只是说明独立轨迹、复杂度和有界损失如何进入分析，不将神经网络无限假设类替换成实验组数，也不为本项目报告该数值证书。已有训练 log 的 L1 加 KL 总和不等于这里的平方动作风险。如需比较，须额外在同一未见 episode、相同目标槽位与归一化下重算指标。

C. 几何表示界

条件期望的最小二乘性质给出

$$a_Q \leq \mathbb{E} \|m_O - f(\hat{G}, C)\|^2.$$

由 L^2 三角不等式及 Lipschitz 性质，

$$\sqrt{a_Q} \leq \sqrt{\epsilon_{\text{suf}}} + L_G \sqrt{\epsilon_G}.$$

代入式(20)即得式(23)。可见关系受 mask 有效域限制时，所有期望应在同一有效域条件化，并额外保留无效域风险，不把该局部界直接宣称为全分布结论。

D. 残差投影恒等式

嵌套信息与条件期望正交性给出

$$\begin{aligned} \mathbb{E} \|E - r\|^2 &= \mathbb{E} \|E - m_h\|^2 + \mathbb{E} \|m_h - m_U\|^2 \\ &\quad + \mathbb{E} \|m_U - r\|^2, \\ \mathbb{E} \|E\|^2 &= \mathbb{E} \|E - m_h\|^2 + \mathbb{E} \|m_h\|^2, \\ \mathbb{E} \|E - m_c\|^2 &= \mathbb{E} \|E - m_h\|^2 + \mathbb{E} \|m_h - m_c\|^2. \end{aligned}$$

两两相减得到式(29)–(30)。这些恒等式要求同一评价分布与同一目标时刻；对不同策略自主产生的轨迹分别算出的风险，不能直接套用。

E. 反馈时序的适用条件

控制周期为 Δ ，第 t 次观察的修正目标为 $t + d, \dots, t + d + H - 1$ ，快更新间隔为 s 。若实际端到端延迟为 ℓ ，且执行在槽位边界对齐，迟到前缀长度可保守记为

$$k = \min\{H, \max(0, \lceil \ell/\Delta \rceil - d)\}.$$

同一计划内若连续轮次均满足 $k < H$ 且 $s + k \leq H$ ，则从可用起点看可维持修正区间覆盖。额外的结果年龄限制、调度丢帧或计划切换仍可能使覆盖失效，所以该关系不等于实机实时保证。结果必须绑定目标槽位；把迟到修正整体向后平移会破坏训练的目标对齐。

参考文献

- [1] S. Ross, G. Gordon, and J. A. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *Proceedings of AISTATS*, ser. PMLR, vol. 15, 2011, pp. 627–635. [Online]. Available: <https://proceedings.mlr.press/v15/ross11a.html>
- [2] P. de Haan, D. Jayaraman, and S. Levine, “Causal confusion in imitation learning,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019. [Online]. Available: <https://arxiv.org/abs/1905.11979>
- [3] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” in *Robotics: Science and Systems*, 2023. [Online]. Available: <https://arxiv.org/abs/2304.13705>
- [4] J. Schulman, S. Levine, P. Moritz, M. I. Jordan, and P. Abbeel, “Trust region policy optimization,” in *Proceedings of ICML*, ser. PMLR, vol. 37, 2015, pp. 1889–1897. [Online]. Available: <https://proceedings.mlr.press/v37/schulman15.html>
- [5] S. Tu, A. Robey, T. Zhang, and N. Matni, “On the sample complexity of stability constrained imitation learning,” in *Proceedings of L4DC*, ser. PMLR, vol. 168, 2022, pp. 180–191. [Online]. Available: <https://proceedings.mlr.press/v168/tu22a.html>

- [6] K. Sendai, M. Alvarez, T. Matsushima, Y. Matsuo, and Y. Iwasawa, “Leave no observation behind: Real-time correction for VLA action chunks,” arXiv:2509.23224, 2025. [Online]. Available: <https://arxiv.org/abs/2509.23224>
- [7] G. E. Fainekos and G. J. Pappas, “Robustness of temporal logic specifications for continuous-time signals,” *Theoretical Computer Science*, vol. 410, pp. 4262–4291, 2009. [Online]. Available: <https://www.georgejappas.org/wp-content/uploads/2024/04/TCS-FP09.pdf>
- [8] N. Ravi *et al.*, “SAM 2: Segment anything in images and videos,” arXiv:2408.00714, 2024. [Online]. Available: <https://arxiv.org/abs/2408.00714>