

Semantic-Guided Imitation Learning with History-Conditioned Feedback

Abstract—视觉模仿学习在动态交互中既需要提取任务相关信息，也需要响应执行期间的新变化。本文研究语义监督、几何查询表示和历史条件反馈改善任务表现的条件。首先，在共同任务完成目标下分析模仿误差、分布覆盖与任务敏感性的关系；随后讨论确定性语义作为归纳偏置的作用，以及历史残差降低动作风险所需的信息和拟合条件。基于这些分析，构建语义增强动作块策略与历史条件残差反馈框架。

（待补：最终实验平台、任务范围、对照结果及定量结论；摘要要在完整评测后定稿。）

Index Terms—Imitation learning, semantic representations, visuomotor control, residual feedback.

I. Introduction

（待补正文：以视觉模仿学习在动态交互中的任务相关表示和执行反馈不足为问题起点；区分动作拟合、任务进展表征与任务成功。避免将 ACT 或 DP 概括为完全没有反馈。）

（待补正文：概括现有方法的具体缺口，引出语义监督、任务相关查询以及历史条件残差；任务作为验证载体，不限制方法定义。）

（待补贡献列表：分别陈述条件性分析、方法机制和受控实验证据；不将已知性能差分与投影恒等式本身列为新定理贡献。）

（待补：经完整统计核验的核心实验结果和文章结构介绍；此处暂不填入初步成功率。）

II. Related Work

A. Visuomotor Imitation Learning and Action Chunking

（待补正文：ACT、DP 与动作块执行；比较观察更新、动作聚合和反馈接口，核实原始论文。）

B. Semantic and Task-Structured Representations

（待补正文：语义辅助、对象关系、查询表示与几何辅助监督；明确本方法不是直接监督注意力图，也不是显式阶段规划器。）

C. History-Conditioned Policies and Residual Feedback

（待补正文：部分可观测控制、循环记忆、残差策略及实时动作块纠偏；区分监督学习与强化学习，逐项核对最接近工作。）

III. Problem Formulation and Theoretical Analysis

本章围绕共同的任务完成目标建立分析链条：动作误差只有在覆盖和任务敏感性等条件受控时，才能约束失败风险；任务相关表示旨在缓解有限数据下的表示误差，更新观测与历史则用于减少执行时的信息缺失。以下命题是条件性结论，不假定加入语义、查询或记忆就必然提高成功率。

A. Task and Learning Problem Formulation

1) 部分可观测的非线性交互：考虑机器人通过动作改变环境状态与可见性的交互任务。以 s_t 为物理隐状态， c_t 为离散交互模式， u_t 为一个或多个执行器的联合动作， $o_t = (I_t^{1:V}, q_t)$ 为 $V \geq 1$ 个视角及本体观测，可写为

$$\begin{aligned} s_{t+1} &= f_{c_t}(s_t, u_t, \xi_t), \\ c_{t+1} &= \chi(s_t, c_t, u_t, \xi_t), \\ I_t^v &= h_v(s_t, \nu_t), \quad v = 1, \dots, V. \end{aligned} \quad (1)$$

不预设已知动力学、固定接触模式或可直接观测的完整状态。遮挡使任务相关信息的可见性随交互改变，连续形变与模式切换使动力学可能非线性、非光滑。同一当前观察可能对应不同的隐藏运动状态。联合动作允许多个执行器通过共享环境耦合，而不将其限制为独立控制。

策略依据因果信息 $\mathcal{H}_t = (o_{0:t}, u_{0:t-1})$ 及任务条件 ℓ 生成指令。此处不指定输入模态的编码方式、记忆架构、阶段头或动作块分工。交互模式 c_t 与任务阶段也不相同：前者描述局部动力学，后者描述任务进展。多阶段任务可由多个条件及其时间关系表达，不要求预先固定阶段数。

2) 抽象任务函数与视觉评价：令 z_t 为理想的任务相关评价变量， ℓ 指定任务谓词、时间范围及可选的顺序约束。定义

$$\Psi_\ell = \Phi_\ell(z_{0:T}), \quad J_\ell(\pi) = \mathbb{E}_\pi[\Phi_\ell(z_{0:T})], \quad (2)$$

其中 $\Phi_\ell: \mathcal{Z}^{T+1} \rightarrow \{0, 1\}$ 是任务完成函数。不同任务改变 Φ_ℓ 的具体形式，而保持学习目标为提高 J_ℓ 。若任务只求时限内某一时刻满足条件，则是上述定义的特例：

$$\Phi_\ell(z_{0:T}) = \mathbf{1}\{\exists t \leq T: g_{\ell,j}(z_t) \geq 0, \forall j\}. \quad (3)$$

需要顺序或保持要求时，改用相应的时序组合；不把一种具体操作的过程顺序强加给所有任务。谓词组合与裕量评价可参考时序逻辑的信号解释 [1]，但本方法不因此假设配备逻辑规划器。

称任务为视觉可评估，是指在声明的观测条件与评价域内，存在函数 $\mathcal{V}_\ell$ ，使理想视觉历史 $I_{0:T}^{*,1:V}$ 足以区分完成事件：

$$\Phi_\ell(z_{0:T}) = \mathcal{V}_\ell(I_{0:T}^{*,1:V}). \quad (4)$$

式(4)是适用条件，不是所有物理任务的事实。若成功与失败的两个物理过程产生不可区分的视觉历史，则任何纯视觉评价器均不能保证辨别，必须增加观测或限制评价域。实际带噪观测与学习到的评价器只近似满足该关系： $\hat{z}_{0:T} = \mathcal{E}(I_{0:T}^{1:V})$ ， $\Psi_\ell = \Phi_\ell(\hat{z}_{0:T})$ 。观测不足时应允许评价未确定，而不是把缺失估计直接当作成功。

评价变量不必是策略的充分控制状态。即使完成条件能从当前图像确定，选择怎样运动仍可能需要速度、接触或历史信息。因此，视觉可评价完成、单帧可判别完成、单帧足以决策是三个不同命题。任务评价器也不必作为策略在线输入；它可以独立用于实验验证。

3) 表示误差与任务判别可靠性: 在共同可评估域上, 设 $\Phi_\ell(z) = \mathbf{1}\{\rho_\ell(z) \geq 0\}$, 其中 z 简记整段评价变量, 任务裕量满足 $|\rho_\ell(z) - \rho_\ell(\hat{z})| \leq L_\rho \|z - \hat{z}\|$. 连续谓词裕量的有限次 min/max 组合是一个适用例子, 但非连续谓词不自动满足该假设. 对任意 $\gamma > 0$,

$$\mathbb{P}(\hat{\Psi}_\ell \neq \Psi_\ell) \leq \mathbb{P}(|\rho_\ell(z)| \leq \gamma) + \frac{L_\rho^2 \mathbb{E}\|z - \hat{z}\|^2}{\gamma^2}. \quad (5)$$

若真实裕量超过 γ 且误差小于 γ/L_ρ , 符号不变; 联合界与 Markov 不等式给出此式. 它表明判别错误取决于任务相关表示误差与边界附近的样本质量, 而不只是整体视觉重建或像素分类精度. 这是评价可靠世界, 不是策略完成概率改进定理: 可靠辨认状态仍须配合适当的动作与执行反馈. 实际任务的谓词、阈值及评价域仅在实验章节实例化.

B. From Imitation Error to Task Success

当参考专家可靠、部署状态被示范分布充分覆盖、动作误差能够泛化, 且任务对动作偏差的敏感程度受控时, 较小的动作风险能够支持更好的任务成功率下界, 但不能保证两个策略的实际成功率按平均动作误差排序. 本节先用有限时域性能差分恒等式, 将失败概率差写成部署分布下的任务优势累积; 再通过动作敏感性、分布覆盖及泛化条件, 将其上界转换为可泛化动作误差的函数; 随后用完整覆盖下的反例及状态相关敏感性, 说明任务更依赖哪些状态上的预测准确性. 现实中的有限数据、有限覆盖和有损观察难以满足理想保证, 因此下一节研究语义及几何监督能否改善任务相关表示, 再下一节研究更新观察和历史能否补足执行中的信息缺失. 三者处理不同缺口, 不把新增模块当作自动恢复所有理想条件的手段.

1) 任务目标与分析假设: 任务在固定时域 T 内运行, 成功事件为 $\Psi = 1$, 失败包含超时和预先指定的违规条件. 所有策略使用同一初始分布、环境转移和成功判据:

$$J(\pi) = \mathbb{P}_\pi(\Psi = 1), \quad F(\pi) = 1 - J(\pi). \quad (6)$$

为建立条件性结果, 令 x_t 为共同的充分决策状态, $\pi(x_t)$ 为实际执行指令. 必要的任务记忆、计划和时序状态可纳入 x_t , 使终端事件可由增广状态表达. 这不声称单帧 RGB 满足 Markov 性. 若只能使用有损观测或记忆编码, 其信息缺失须另行计入, 不能在应用理论时省略.

参考策略 π_E 假设为定义在所考察状态上的确定性专家. 参考策略不必全局最优, 但须有可接受的 $J(\pi_E)$. 示范存在互相矛盾的动作模式时, 动作条件均值不必仍是有效专家, 此时不能把平方误差最优解直接代入下面的专家假设. 令 D 为固定的正对角动作尺度矩阵, 定义

$$e_\pi(x) = D^{-1}(\pi(x) - \pi_E(x)). \quad (7)$$

D 来自训练集, 所有比较沿用相同尺度; 归一化并不代表各关节具有相同任务代价. 以下讨论执行时刻的动作误差, 不默认全动作块各槽位平均误差等于实际执行误差.

令 $Q_t^E(x, a)$ 表示在 x 执行 a 后始终遵循专家的终端失败概率, $V_t^E(x) = Q_t^E(x, \pi_E(x))$, $A_t^E = Q_t^E - V_t^E$. d_π^t 为执行策略 π 的状态分布, $\bar{d}_\pi$ 为 (t, x) 的均匀时间混合. 由性能差分恒等式 [2] 的有限时域形式,

$$F(\pi) - F(\pi_E) = \sum_{t=0}^{T-1} \mathbb{E}_{d_\pi^t} A_t^E(x, \pi(x)). \quad (8)$$

下面给出该恒等式及风险界的证明. 等式的对象是闭环访问分布下、按任务后果衡量的误差, 不是训练集的平均动作距离.

2) 覆盖、泛化与任务敏感性的共同作用: 记专家分布平方动作风险为 $\epsilon_E = \mathbb{E}_{\bar{d}_E} \|e_\pi\|^2$. 假设部署分布被专家分布控制, 且动作偏离引起的任务风险有界:

$$\bar{d}_\pi \ll \bar{d}_E, \quad \frac{d\bar{d}_\pi}{d\bar{d}_E} \leq C, \quad (9)$$

$$A_t^E(x, a) \leq L \|D^{-1}(a - \pi_E(x))\|. \quad (10)$$

C 表示覆盖程度而非样本条数, L 表示任务对动作偏差的敏感程度. 部署分布偏移和误差传播是模仿学习的重要困难 [3]; 稳定性约束下的样本复杂度分析 [4] 提供相关背景, 但不直接保证本方法满足以下条件. 覆盖假设要求相关状态及其频率, 不只是物体初始位置网格齐全. 完整连续历史包含确定性动作时, 两策略的历史分布甚至可能互相奇异; 因此不能未经验证就在全历史空间假定有限 C . 采用低维状态近似虽方便, 也必须检查其充分性. 接触不连续、硬阈值成功事件或悬崖式失败附近, 有限且有用的 L 也可能不存在.

命题 1 (动作风险到成功率的条件性界): 若式(9)–(10)成立, 则

$$J(\pi) \geq J(\pi_E) - TL\sqrt{C\epsilon_E}. \quad (11)$$

若以至少 $1 - \delta$ 的概率有 $\epsilon_E \leq \hat{\epsilon}_E + g_\delta$, 则同概率下

$$J(\pi) \geq J(\pi_E) - TL\sqrt{C(\hat{\epsilon}_E + g_\delta)}. \quad (12)$$

下界可截断到零.

证明见本小节后文. 式(12)中的 g_δ 不可忽略: 训练误差下降但泛化间隙扩大, 不给出更强保证. 若仅有同轨迹相邻帧上的随机划分, 不能把帧数当作独立样本数. 该界也可能很松, 本文不以未知的 C, L 生成数值成功率预测.

覆盖不全时, 设 $\bar{d}_\pi = (1 - \kappa)d_{\text{cov}} + \kappa d_{\text{out}}$, 其中 $d_{\text{cov}} \leq C\bar{d}_E$, 式(10)只在覆盖部分成立. 利用终端失败优势至多为 1,

$$F(\pi) - F(\pi_E) \leq T[(1 - \kappa)L\sqrt{C\epsilon_E} + \kappa]. \quad (13)$$

覆盖域内误差趋零仍不能消除域外项. 这里 κ 是未覆盖的平均访问质量, 不是每条轨迹必然失败概率, 故保留保守的 T 因子. 更换策略也会改变 C 和 κ .

3) 风险界证明与有限样本解释: 令 $V_T^E(x_T) = \mathbf{1}\{\Psi = 0\}$, 状态包含评价终端事件所需的记录. Bellman 关系为 $Q_t^E(x, a) = \mathbb{E}[V_{t+1}^E(x_{t+1}) | x, a]$. 因此沿 π 的轨迹,

$$\begin{aligned} \sum_t \mathbb{E}_\pi A_t^E(x_t, \pi(x_t)) &= \sum_t \mathbb{E}_\pi [V_{t+1}^E(x_{t+1}) - V_t^E(x_t)] \\ &= \mathbb{E}_\pi V_T^E - \mathbb{E}_{x_0} V_0^E \\ &= F(\pi) - F(\pi_E). \end{aligned}$$

这里以终端状态的指示变量定义价值; 环境随机性由条件期望积分. 相同初始分布是最后一步成立的必要条件. 随后

$$\begin{aligned} F(\pi) - F(\pi_E) &\leq TL \mathbb{E}_{\bar{d}_\pi} \|e_\pi\| \\ &\leq TL \sqrt{\mathbb{E}_{\bar{d}_\pi} \|e_\pi\|^2} \\ &\leq TL \sqrt{C\epsilon_E}, \end{aligned}$$

得到式(11). 在覆盖混合的两部分分别使用此论证和 $A_t^E \leq 1$, 得到式(13).

例如，预先固定的有限策略集合含 M_Π 个候选，每条专家轨迹的平均平方损失位于 $[0, B_\ell]$ ， n 条轨迹独立采样。Hoeffding 不等式及联合界给出

$$g_\delta = B_\ell \sqrt{\frac{\log(M_\Pi/\delta)}{2n}}. \quad (14)$$

此时可对数据选择的候选使用式(12)。这只是说明独立轨迹、复杂度和有界损失如何进入分析，这一有限类结果不能以实验组数替代神经网络假设类复杂度，因此不作为本文系统的数值证书。已有训练 $\log$ 的 L1 加 KL 总和并不等于这里的平方动作风险。如需比较，须额外在同一未见 episode、相同目标槽位与归一化下重算指标。

4) 更小误差不等于更高成功率：下界改善不等于两个真实成功率的单调排序。即使 $T = 1$ 且训练测试分布完全一致，结论仍不成立。设两个状态等概率出现，专家均输出零，状态 1 的失败概率为 $\min(1, 100a^2)$ ，状态 2 任意动作均成功。策略 P 分别输出 $(0.1, 0)$ ，策略 Q 输出 $(0, 0.2)$ ，则

$$\epsilon_P = 0.005 < 0.020 = \epsilon_Q, \quad J(P) = 0.5 < 1 = J(Q). \quad (15)$$

这不是覆盖缺失，而是误差发生位置及后果不同。在实际任务中，工具接触前后的少量误差可能比自由运动误差重要得多。

严格的策略改进条件应相对于当前基线 π_0 的任务优势描述：

$$\sum_t \mathbb{E}_{d_{\pi_1}} A_t^{\pi_0}(x, \pi_1(x)) < 0 \implies J(\pi_1) > J(\pi_0). \quad (16)$$

普通 L1/MSE 没有直接监督该条件。只有额外建立代理损失与任务优势的关系，并控制访问分布变化，才可谈一致性。本文的合理主张是：降低可泛化的、任务相关的执行误差，是提高成功率的支持路径，而非充分的模型排名规则。

5) 从理想保证到实际缺口：前面的保证指出三个现实困难。有限数据与表征学习困难：即使某类控制关系在示范中出现，有限样本也未必足以使模型从高维外观中发现并保留该关系；低训练误差并不等于低泛化误差。覆盖不全：外观组合缺失与控制状态缺失不同，前者可能通过不变先验缓解，后者不能仅靠重新编码已知图像补全。观察与执行不同步：生成动作时的观察可能不充分或已经过时，即使图像表示准确，也不能表达尚未观察到的后续变化。这些缺口分别引出表示监督与增量反馈，但尚未解释为何应强调某些语义关系。

为连接关键状态与表示选择，将式(10)的统一常数细化为非负的状态相关敏感性 $w(t, x)$ ：

$$A_t^E(x, a) \leq w(t, x) \|D^{-1}(a - \pi_E(x))\|. \quad (17)$$

定义 $\epsilon_{E,w} = \mathbb{E}_{\bar{d}_E}[w\|e_\pi\|^2]$ ， $\bar{w}_\pi = \mathbb{E}_{\bar{d}_\pi} w$ ，假设这些量有限。由加权 Cauchy-Schwarz 及同一覆盖条件，

$$\begin{aligned} F(\pi) - F(\pi_E) &\leq T \mathbb{E}_{\bar{d}_\pi}[w\|e_\pi\|] \\ &\leq T \sqrt{\bar{w}_\pi C \epsilon_{E,w}}. \end{aligned} \quad (18)$$

取 $w \equiv L$ 即回到式(11)。这说明高敏感状态上的误差对该保证影响更大，而不只是这些状态应在叙述上被称为关键。这里 w 是分析中的任务敏感性，不是现有训练的权重，更不是 SAM2 标签质量分数；关键事件标记也不自动等于已估计的 w 。

由此得到下一节的明确问题：如果高敏感状态下需要区分的控制关系，能够由可靠语义几何表示，辅助监督能否减少这些状态上的表示与动作误差？关系在视觉上显著并不足够，还必须对动作有用。若关键差异来自视觉不能区分的隐变量，或来自完全未见的控制规律，语义表示并不能解决它。式(18)提供需要改善的风险对象，而不是直接证明语义或 QToken 已经改善了它。

C. Task-Relevant Representations under Limited Data

上一节把困难定位为有限数据下的任务相关误差，而非笼统的像素信息不足。由已有 RGB 确定的语义图不会增加原始观测信息，但外部分割监督与几何查询监督可以提供任务相关的归纳偏置，在有限数据下减少表示丢失的信息和实际动作读出误差。收益要求所选几何关系与控制有关、估计足够可靠，且策略能够利用该表示，新增编码与监督的代价没有抵消这些收益。本节先用条件期望将平方动作风险分解为不可约风险、表示损失与读出误差，再由几何的近似充分性及 Lipschitz 条件，推导几何估计误差对动作风险的条件性上界，并在同一任务敏感性加权分布下将其连接回上一节的任务界，最后分析伪标签与不可见关系如何限制该结论。因此，实验须区分几何可读出、动作实际使用该表示，以及闭环任务表现改善这三个层次。

1) 增加原始观测与加入语义先验不同：在固定评价分布 μ 上，令 Y 为相同目标执行时刻的归一化示范动作，所有变量二阶可积，所有模型参数视为训练后固定。若 X 为已有输入， I 为新增视角或更新的图像，则理想平方预测风险满足

$$R^*(X) - R^*(X, I) = \mathbb{E}\|\mathbb{E}[Y | X, I] - \mathbb{E}[Y | X]\|^2 \geq 0. \quad (19)$$

额外信息改变条件动作均值时才严格改善；实际学习误差可能抵消该收益。

若分割图 $S = g(I)$ 由已有 RGB 确定，固定分割器后

$$\sigma(I, S) = \sigma(I), \quad R^*(I, S) = R^*(I). \quad (20)$$

所以语义不是对原始 RGB 增加新的测量信息。外部分割标签及预训练引入了额外的学习先验，将对象身份与空间范围直接编码，可能使有限数据模型更易学习合适映射。这也说明只比示范条数不足以衡量公平性：额外标签、人工审核和预训练均应披露。

令 $\mathcal{O}$ 为共同允许的输入信息， Z 为实际表示， $m_{\mathcal{O}} = \mathbb{E}[Y | \mathcal{O}]$ ， $m_Z = \mathbb{E}[Y | Z]$ 。条件期望正交性给出

$$\begin{aligned} R(p_Z) &= R(m_{\mathcal{O}}) + a_Z + e_Z, \\ a_Z &= \mathbb{E}\|m_{\mathcal{O}} - m_Z\|^2, \quad e_Z = \mathbb{E}\|p_Z - m_Z\|^2. \end{aligned} \quad (21)$$

语义的收益必须落在表示信息损失 a_Z 和实际读出误差 e_Z 的净下降上。增加 token 与共享编码器也可能增加优化困难，不能只看输入更直观就预设收益。

2) 归纳偏置能处理哪类覆盖缺失：将控制相关变量记为 (G, C) ，无关外观记为 N 。若不同环境均满足

$$\mathbb{E}[Y | G, C, N] = f(G, C), \quad (22)$$

且变化只发生于 N ，则同一几何决策函数无需重新学习每种纹理。例如目标和工具关系不变但背景颜色改变，可靠语义可以减少对外观偶然相关性的依赖。这要求语义估计器本身对该变化也可靠，且相关几何和控制条件已有覆盖。它不解决从未见过的工具接触模式、物体动力学、目标完全消失后的任意恢复。

式(22)是需验证的假设，不是分割标签自动获得的因果结论。历史中上一动作、夹爪状态等也可能成为错误捷径[5]。共享 RGB 路径并未被强制成为不变表示；应通过外观干预和几何保持对照检验，不能仅用分割 IoU 解释策略的分布外表现。

3) 几何监督 $QToken$ 的条件性作用: 令 G 为任务几何， C 为必要控制上下文。假设存在关于几何为 L_G -Lipschitz 的 f ，使

$$\mathbb{E}\|m_{\mathcal{O}} - f(G, C)\|^2 \leq \epsilon_{\text{suf}}. \quad (23)$$

ϵ_{suf} 容纳几何之外的姿态、接触、历史等因素。从查询表示 Z_Q 可读出 $\hat{G} = d(Z_Q)$ ，并可访问 C ，设 $\epsilon_G = \mathbb{E}\|\hat{G} - G\|^2$ 。

命题 2 (几何表示的误差界): 实际动作读出误差记为 e_Q ，则

$$R(p_Q) - R(m_{\mathcal{O}}) \leq (\sqrt{\epsilon_{\text{suf}}} + L_G \sqrt{\epsilon_G})^2 + e_Q. \quad (24)$$

证明: 条件期望的最小二乘性质给出

$$a_Q \leq \mathbb{E}\|m_{\mathcal{O}} - f(\hat{G}, C)\|^2.$$

由 L^2 三角不等式及 Lipschitz 性质，

$$\sqrt{a_Q} \leq \sqrt{\epsilon_{\text{suf}}} + L_G \sqrt{\epsilon_G}.$$

代入式(21)即得式(24)。可见关系受 mask 有效域限制时，所有期望应在同一有效域条件化，并额外保留无效域风险，不把该局部界直接宣称为全分布结论。

若基线的超额风险 $a_0 + e_0$ 大于右侧，则有严格平方风险改善。但基线表示信息损失的下界通常难以估计；一个较差的探针误差不是其下界。该命题给出可能的充分条件，不证明加入辅助监督后必然满足这些条件。

语义图给出对象区域；几何监督 query 进一步要求指定关系能够被编码和读出。具体监督关系由任务选择，而不要求一种固定的几何量或完整阶段标签。辅助 loss 给 query 及其关联视觉特征提供梯度，但不指定 attention map，也不保证动作 decoder 实际利用了它。因此需同时检查几何精度、query 消融后的动作变化和闭环成功率。几何查询本身不实现阶段切换或停止判定。

4) 把几何表示界接回任务性能界: 仅证明平均几何误差变小，尚未回答上一节提出的关键状态问题。令 $Z_w = \mathbb{E}_{\tilde{d}_E} w > 0$ ，定义归一化的敏感性加权分布 $d\mu_w = (w/Z_w)d\tilde{d}_E$ 。本节的投影分解与几何界可统一在 μ_w 下重新推导，但条件均值及所有误差也必须按该分布重新定义，不能只给最终公式乘一个权重。以角标 w 表示这些量，记

$$B_w = R_w^* + (\sqrt{\epsilon_{\text{suf},w}} + L_G \sqrt{\epsilon_{G,w}})^2 + e_{Q,w}. \quad (25)$$

若监督目标确为前节参考专家在同一决策状态、同一执行时刻的动作，则 $\epsilon_{E,w} = Z_w R_w(p_Q) \leq Z_w B_w$ ，从而

$$J(\pi_Q) \geq J(\pi_E) - T \sqrt{\tilde{w}_{\pi_Q} C Z_w B_w}. \quad (26)$$

R_w^* 表示允许观察下仍然不可约的预测风险。示范动作含模式歧义或目标时间错位时，不能不经校验就把监督风险代入此式。

这给出了层层连接的充分条件：任务敏感的控制关系在所选几何中近似充分，其估计与读出误差足够小，且部署覆盖受控，才有更紧任务保证的可能。严格改善几何表示的动作风险，要求加权几何界的超额部分小于基线的加

权超额风险；仅比较两个上界大小仍不是实际策略排序证明。新增语义不被宣称自动降低 C 、 w 或未覆盖质量 κ ，而是在这些条件成立的范围内改善表示相关风险。

因此，关键状态与 $QToken$ 之间不是直接等号，而是任务敏感性提出需要区分的关系，几何监督尝试让这些关系被保留，动作读出再将其转为更准确的决策。监督了不相关关系，或关系虽准确却未被动作使用，都不能完成这一链条。

5) 伪标签、不确定性与不可见关系: 令 $\tilde{G}$ 为伪标签。无偏假设不是必需的，但真值误差满足

$$\epsilon_G \leq 2\mathbb{E}\|\hat{G} - \tilde{G}\|^2 + 2\mathbb{E}\|\tilde{G} - G\|^2. \quad (27)$$

仅减小伪标签拟合误差不能保证第二项小；稳定地把机械臂误分为目标可能同时具有高时间一致性和高系统偏差。质量分数只能作为诊断和相对权重，须通过独立人工抽样验证。

对标量几何和质量权重 $W \geq 0$ ，加权平方目标的最优读出为

$$d_W(z) = \frac{\mathbb{E}[W\tilde{G} \mid Z = z]}{\mathbb{E}[W \mid Z = z]}, \quad \mathbb{E}[W \mid Z = z] > 0. \quad (28)$$

它不自动等于 $\mathbb{E}[G \mid Z = z]$ 。把困难状态长期降权可能降低其有效覆盖。实际 Smooth L1 的最优解也不直接等于式(28)。对不可见关系，几何界只在有效域解释；目标不可见时面积零仍有效，但目标与工具距离未定义，不能伪造零距离监督。不可见域的策略风险必须单独报告，不能在整体成功率论证中删掉。

6) 表示改善之后仍然缺少什么: 即使上述几何误差和读出误差很小，固定观察下的 R_w^* 仍可能为正：任务相关动态不能总由当前静态几何辨别，执行期间的新变化也不包含在生成原计划的旧观察中。因此，单纯继续强化同一帧的语义监督不能消除全部残余误差。下一节转向扩大可用的因果信息并学习其对当前计划的修正：更新观察响应执行中变化，历史帮助区分动态歧义。这不是取代本节的表示学习，而是针对它没有解决的信息与时序缺口。

D. History-Conditioned Feedback for Execution Correction

上一节改善已有观察的任务相关表示，但不能恢复旧观察没有记录的新变化，也不能保证单帧几何足以区分动态状态。本节针对这一剩余缺口引入增量信息。新观测只有帮助预测当前计划的误差，并产生方向合适、幅度不过大的修正时，才会降低动作风险；历史只有提供当前信息之外的可预测残差，且收益超过编码与拟合代价时，才会进一步改善纠偏。更高观测频率或采用 GRU 本身均不构成改进保证。本节先以条件期望投影分解当前信息、历史与实际残差预测器的风险，再将实际收益写成误差与修正的对齐项减去修正能量；随后通过时间集成的偏差与协方差分解，说明频繁查询为何仍可能受到旧计划偏差影响，最后给出动作风险改善转化为任务成功率改善所需的更强任务方向条件。相应实验应控制基础策略与实际延迟，并通过历史对照及修正方向诊断检验收益来源。

本节先在固定评价分布上分析实际动作修正。若需强调上一节的高敏感状态，可在同一 μ_w 下重新定义全部条件期望与风险；在覆盖和参考动作对齐等条件下，所得动作风险再进入式(18)。这保持了共同的任务目标，但不将离线回放分布直接当作纠偏后的闭环分布。

1) 历史条件残差的可利用信息: 固定评价分布及目标时刻, 令 B 为归一化基础动作, $E = Y - B$. $\mathcal{F}_c$ 包含最新观察、当前关节及计划上下文, $\mathcal{F}_h \supseteq \mathcal{F}_c$ 再包含因果历史。定义 $m_c = \mathbb{E}[E | \mathcal{F}_c]$, $m_h = \mathbb{E}[E | \mathcal{F}_h]$ 。理想历史残差比理想当前帧残差减少的风险为

$$\Delta_h = \mathbb{E}\|m_h - m_c\|^2. \quad (29)$$

同一当前画面但不同的接近速度、接触前后状态或过去遮挡记录, 若需要不同修正, Δ_h 可能为正; 重复帧或无关历史则不保证收益。

令 GRU 与其他输入产生信息 $\mathcal{U} \subseteq \mathcal{F}_h$, 实际残差 r 为 $\mathcal{U}$ 可测, $m_U = \mathbb{E}[E | \mathcal{U}]$ 。

命题 3 (历史编码与残差收益): 设 $\epsilon_{\text{enc}} = \mathbb{E}\|m_h - m_U\|^2$, $\epsilon_{\text{fit}} = \mathbb{E}\|r - m_U\|^2$, 则

$$R(B) - R(B + r) = \mathbb{E}\|m_h\|^2 - \epsilon_{\text{enc}} - \epsilon_{\text{fit}}, \quad (30)$$

$$R(B + r) - R(B + m_c) = \epsilon_{\text{enc}} + \epsilon_{\text{fit}} - \Delta_h. \quad (31)$$

证明: 嵌套信息与条件期望正交性给出

$$\begin{aligned} \mathbb{E}\|E - r\|^2 &= \mathbb{E}\|E - m_h\|^2 + \mathbb{E}\|m_h - m_U\|^2 \\ &\quad + \mathbb{E}\|m_U - r\|^2, \end{aligned}$$

$$\mathbb{E}\|E\|^2 = \mathbb{E}\|E - m_h\|^2 + \mathbb{E}\|m_h\|^2,$$

$$\mathbb{E}\|E - m_c\|^2 = \mathbb{E}\|E - m_h\|^2 + \mathbb{E}\|m_h - m_c\|^2.$$

两两相减得到式(30)–(31)。这些恒等式要求同一评价分布与同一目标时刻; 对不同策略自主产生的轨迹分别算出的风险, 不能直接套用。

历史中的可预测残差必须超过编码和拟合代价才能改善。GRU 是实现选择; 这里不存在 GRU 必然优于 LSTM 或 Transformer 的结论。有界残差与正则可能牺牲拟合最优性, 其影响包含在 ϵ_{fit} 中。最新观测的收益也可用式(19)分析, 但必须与相同目标时间的旧信息比较。对任意实际残差, 还可直接检验

$$R(B) - R(B + r) = 2\mathbb{E}\langle E, r \rangle - \mathbb{E}\|r\|^2. \quad (32)$$

修正方向与误差不一致, 或修正过大, 均可能恶化动作风险。

2) 为何频繁 ACT 与时间集成可能效果不好: ACT 时间集成聚合同一执行时刻的多次预测 [6]。令 $\hat{u}_{\tau|k}$ 为第 k 次查询对 τ 的预测, $w_k \geq 0$, $\sum_k w_k = 1$, 则

$$u_{\tau}^{\text{TE}} = \sum_k w_k \hat{u}_{\tau|k}. \quad (33)$$

它确实使用新观测, 因此不能把残差优势归因于基线没有实时信息。相对同一参考动作 u_{τ}^* , 令预测误差为 $b_k + \xi_k$, $\mathbb{E}\xi_k = 0$ 。对固定权重,

$$\mathbb{E}\|u_{\tau}^{\text{TE}} - u_{\tau}^*\|^2 = \left\| \sum_k w_k b_k \right\|^2 + \sum_{k,l} w_k w_l \text{tr Cov}(\xi_k, \xi_l). \quad (34)$$

相关误差的方差降低有限, 且旧预测在接触变化后可能带有系统偏差。若旧预测为 a 、新预测与当前正确目标均为 b , 旧预测总权重为 α , 则时间集成误差为

$$\|u^{\text{TE}} - b\|^2 = \alpha^2 \|a - b\|^2. \quad (35)$$

此外, 不同接触方案的平均动作未必对应有效接触路径。但不能据此宣称平均总会变差: 平方范数凸性保证

$$\left\| \sum_k w_k e_k \right\|^2 \leq \sum_k w_k \|e_k\|^2, \quad (36)$$

它只是未保证优于最新或最好的单次预测, 也未保证任务成功。

实际比较应固定查询频率、预测年龄及时间集成权重, 并独立测量端到端延迟。式(35)描述一种可能的失效机制, 但不单独识别实机失败的原因。

(待补: 实际部署的时间集成权重、查询频率与结果年龄, 结合受控消融判断该机制是否成立。)

3) 残差的区别与任务改进边界: 残差显式条件于正在执行的计划, 学习该计划在新证据下应改多少; 它不要求每次独立重选完整动作模式。时间集成保留的是多次预测的加权记忆, 不等于学习了观察历史的状态估计。若直接预测器具有同样的信息、函数能力、训练目标及算力, $B + r$ 与直接动作预测可互相参数化, 不存在表达能力上的普遍优越性。冻结基础策略、零初始化、有界局部更新和匹配时序的监督是归纳偏置, 不是无条件改进保证。残差同样可能受到时延、错误记忆和覆盖缺失影响。

对任务成功率, 设 Q_t^B 是基础控制器的失败代价, 在归一化动作 b 周围二阶光滑, Hessian 上界为 M 。则

$$A_t^B(x, b + r) \leq \nabla_b Q_t^B(x, b)^\top r + \frac{M}{2} \|r\|^2. \quad (37)$$

若右侧在修正后控制器的访问分布上跨时刻求期望严格为负, 式(16)给出成功率严格提升。这要求修正沿任务风险下降方向, 比式(32)更强。当前监督残差没有学习 Q^B , 不能声称已验证此条件; 小动作误差与局部任务风险方向一致的接触模式、覆盖及安全裕量需要实验支撑。限幅也不能独自保证该条件。

训练只含成功示范时, 纠偏器学习的是示范观测下基础预测的残差。模型自主偏离后, 同时索引的示范指令未必仍是合适恢复动作; 没有反事实恢复标签就不能承诺大范围恢复。离线回放检验式(32), 闭环测试另行检验修正后分布及任务后果, 两者必须分开。

4) 反馈时序与有效修正覆盖: 控制周期为 Δ , 第 t 次观察的修正目标为 $t + d, \dots, t + d + H - 1$, 快更新间隔为 s 。若实际端到端延迟为 ℓ , 且执行在槽位边界对齐, 迟到前缀长度可保守记为

$$k = \min\{H, \max(0, \lceil \ell / \Delta \rceil - d)\}.$$

同一计划内若连续轮次均满足 $k < H$ 且 $s + k \leq H$, 则从可用起点看可维持修正区间覆盖。额外的结果年龄限制、调度丢帧或计划切换仍可能使覆盖失效, 所以该关系不等于实机实时保证。结果必须绑定目标槽位; 把迟到修正整体向后平移会破坏训练的目标对齐。

E. Testable Implications

分析给出三个需要分别检验的环节, 而非用单一成功率验证全部假设。首先, 在统一动作尺度、执行槽位和独立轨迹上比较动作风险, 并区分接触等关键事件附近与普通状态的误差, 以检验平均误差的解释边界。其次, 语义与查询的收益应同时体现为相关几何可读出、策略确实利用该表示以及闭环行为改善; 仅降低辅助损失不足以完成这一论证。最后, 历史反馈应在同一冻结基础策略上检验残差与误差的对齐、历史的增量贡献和延迟鲁棒性。上述实验可支持机制解释, 但不能从有限样本证明全状态空间的覆盖或稳定性假设。

(待补: 各命题对应的实验编号、预注册比较项及判定标准; 未知的覆盖常数和敏感性常数不填入推测数值。)

IV. Method

A. Framework Overview

框架包含离线语义学习、语义与几何监督的基础策略，以及条件于执行历史的残差反馈。基础策略生成动作块；反馈模块利用较新观测修正尚未执行的动作槽位。语义与查询针对第 III 节中的表示误差，历史反馈针对时变信息与执行偏差，但训练目标并不直接优化任务成功概率。

（待补：方法总览图，标明冻结模块、可训练模块、监督来源、因果信息流及两条推理更新频率。）

B. 先控制标注噪声，再学习策略

方法将标签质量、表示监督和在线反馈分开处理。首先由类别定义和少量代表帧生成离散框/点 JSON 提示，渲染后人工审核；SAM2 [7] 传播种子视频。通过时间 IoU、面积跳变、质心跳变、连通域异常及可用时的双向一致性定位待重试片段，少量人工复核后训练分视角 YOLO 提示器，再扩展到全数据集并迭代修复。这些诊断分数不是校准概率，也不能发现所有一致性错误。未来帧仅用于离线标注，不能进入在线反馈。

数据按 episode 划分。作为全流程未见测试的片段不得参与提示器、分割器、策略或阈值的拟合；不满足这一条件的旧结果须披露实际已见范围。质量分数影响离线重试和有效样本选择，并用于几何监督的相对加权。分割模型采用类别加权 CE 与前景 Dice；类别权重与逐帧质量权重不同。分割质量需由独立人工审计支持，而非仅比较模型与其自身伪标签。

C. 语义输入与几何监督查询

为各视角单独训练并冻结轻量 U-Net；各视角允许不同类别集合，并保留相应的类别差异。

（待核实：最终实验的 front/side 类别表与分割 checkpoint；V5 记录含背景分别为 7 类和 5 类。）

完整视野缩放到 480×270 ，概率 $P^v(c, u)$ 通过固定调色板 $p_c \in [0, 1]^3$ 转为

$$S^v(u) = \sum_c P^v(c, u) p_c. \quad (38)$$

这是 soft 颜色图，不是 argmax；多类别到三通道通常不可逆。每路 RGB 及对应语义图分别通过同一个 ResNet18 和投影后进入 ACT，双视角共四路视觉 token，单视角两路，使用原 ACT 位置编码，不加入 camera/modality embedding。保留 RGB 是为了避免几何类别丢弃未标注的姿态与接触线索；共享骨干是实现选择，而不是理论结论。

三个 512 维可学习 query 与视觉、关节等 token 共同进入 encoder，其输出由辅助头预测 front 几何：

$$\begin{aligned} G_1 &= |M_O|/(WH_I), \\ G_2 &= \|c_O - c_R\|/\sqrt{(W-1)^2 + (H_I-1)^2}, \\ G_3 &= \bar{c}_O - \bar{e}_{T,L} \in \mathbb{R}^2. \end{aligned} \quad (39)$$

c_O, c_R 为目标与区域质心；tool mask 在归一化图像平面上做 PCA 主轴拟合，选择两个投影极值端点中横坐标更小的 $\bar{e}_{T,L}$ 。该端点是图像约定，不自动等同于真实接触端。

目标不可见时面积零仍监督；关系成员不可见时屏蔽对应关系监督。令 v_{bi} 表示几何组有效， q_{bi} 为相关类别质量

最小值， $w_{bic} = v_{bi} \min(q_{bi}/0.95, 1)$ 。当前几何 loss 按组计算

$$L_G = \frac{1}{3} \sum_{i=1}^3 \frac{\sum_{b,c} w_{bic} \ell_{0.01}(\hat{G}_{bic} - \tilde{G}_{bic})}{\max(1, \sum_{b,c} w_{bic})}. \quad (40)$$

ℓ_β 为 Smooth L1；三组维度为 1、1、2。归一化后权重主要改变样本的相对贡献，全组同倍降权可能被分母抵消。ACT 优化 $L_{L1} + \lambda_{KL} L_{KL} + \lambda_G L_G$ ， λ_G 为几何监督权重；几何 loss 不更新冻结分割器。动作 decoder 可读取完整 encoder 上下文，包括 query 隐藏状态。该策略不包含额外阶段分类、阶段切换或停止头。区域质心距离不等价于完整包含率；查询提供任务相关几何表征，而非显式完成判定。

D. 冻结基础策略的历史条件纠缠

基础策略训练后冻结，残差分支每次只编码新到达的双视角 RGB，完整视野缩放到 320×180 ，冻结骨干后池化为每视角 $2 \times 3 \times 512$ 特征；窗口内旧视觉使用缓存，不重复分割或编码。上下文包括实际 follower 关节、因果速度估计、上一发送指令、未来基础动作及相对关节差、有效槽位、计划年龄和观察间隔。

完整方法将当前生效基础计划的查询隐藏状态与最新 RGB 特征结合。查询状态在基础计划更新时重新计算，在两次计划更新之间保持不变；因此它提供计划相关上下文，而不是快更新时刻的实时几何测量。仅 RGB 反馈与额外分割描述反馈作为消融变体，比较时应保持基础策略一致。

最近 8 条因果记录经 128 维投影与单层 hidden128 的 GRU 编码；每次从窗口起点的零隐藏状态重算，5Hz 下跨度约 1.4 秒。断流或重置清空历史。快头输出

$$\delta a_j = \beta \odot \tanh([W_r h + c_r]_j), \quad \hat{a}_j = b_j + \delta a_j. \quad (41)$$

输出层零初始化，每维限幅由训练集基础误差 P95 设定，当前裁剪到 $[0.05, 5]$ 原生命令单位，换平台需核对单位。监督使用 leader 示范指令、follower 观测，不混同此前 follower-delta 实验。当前损失为有效槽位上标准差缩放后的 Smooth L1 ($\beta = 0.1$) 及 10^{-3} 的平方残差正则；AdamW 学习率 10^{-4} ，batch128，最多 50 轮，验证 8 轮不改善早停，以验证缩放 MAE 选择 checkpoint。理论平方风险另外计算，不从该混合训练 loss 直接推断成功率。

E. 目标槽位对齐与失效处理

以控制频率 30Hz、基础动作块 60 步、每 30 步重规划为当前实现设置；快更新每 6 帧一次，目标延迟 3 帧，输出 9 步残差。第 6 帧观察对应第 9 至 17 帧，第 12 帧观察对应第 15 至 23 帧，相邻修正区间重叠 3 帧；及时使用首槽的端到端预算为 100ms。所有结果绑定 plan ID 和目标执行槽位，只替换尚未执行的对应残差，始终加到原基础动作而非累加旧修正。计划切换清空旧计划残差，迟到丢弃过期前缀而不移动目标时间。

（待核实：最终部署的观察年龄、残差年龄上限及超时处理；V5 记录分别为 0.15 秒和 0.4 秒。）

无有效残差时回退有效基础动作，基础动作也过期时使用已验证的硬件安全处理，不得无限复用最后指令。实时评测应包含图像获取、预处理、编码、队列、GRU 及发布延迟，而非仅报告神经网络 kernel 耗时。

(待补：以最终训练配置核对本章全部超参数，包括图像尺寸、查询维数、历史窗口、损失系数、动作单位及训练预算；当前数值沿用 V5，不构成新增实测。)

F. Online Execution Procedure

接收带时间戳的新观测，并更新因果特征缓存。

if 到达基础策略更新时刻 then

生成基础动作块与查询上下文，分配新的计划编号，清空旧计划修正。

end if

if 到达反馈更新时刻 then

从当前计划、最新观测及历史窗口预测指定未来槽位的残差。

end if

校验结果的计划编号与目标时间，仅保留未过期且尚未执行的修正。

对当前槽位执行基础动作加有效残差；缺少有效修正时使用基础动作。

若基础计划也已失效，进入经平台验证的安全处理。

(待补：平台安全处理与延迟统计；本算法仅描述推理流程，不构成硬件安全证明。)

V. Experimental Validation

A. Platforms, Tasks, and Evaluation Protocol

1) *Bimanual Exposure and Execution*: 评价首先在参考视角定义完整目标区域足迹 R^* ，并令 Ω 为该参考视角的整幅图像域。令 O_t^* 为目标完整投影， C_t 为遮挡布料投影。当目标完整可评估且 $|O_t^*| > 0$ 时，定义

$$p_{in}(t) = \mathbf{1}\{O_t^* \subseteq R^*\}, \quad (42)$$

$$a_C(t) = |C_t \cap \Omega|/|\Omega|, \quad (43)$$

$$p_{restore}(t) = \mathbf{1}\{a_C(t) \geq \theta_C\}. \quad (44)$$

R^* 不是当前可见 region 类别 mask：互斥分割使 object 与可见 region 不重叠，直接求交会误判。固定目标区域可由无遮挡参考帧独立标注；相机或区域移动时须重新估计。仅有局部可见的目标 mask 也不能替代 O_t^* 来证明整个物体已进入区域。

当前布料复原不会重新遮挡目标物体，复原指标是布料在画面中的面积占比，不是目标被遮挡比例，也不是默认裁剪桌面 ROI 后的占比。按这一要求，任务在规定时间内满足下式即可完成：

$$\Phi_\ell(z_{0:T}) = \mathbf{1}\{\exists t \leq T : p_{in}(t) = 1 \wedge p_{restore}(t) = 1\}. \quad (45)$$

两项必须在同一完成时刻成立：不能仅凭初始布料面积较大，也不能凭曾经入区但随后又移出的记录判成功。若协议另要求连续 d_C 帧确认，则在同一窗口内检验这两个谓词，并要求窗口终点不超过 T ；未指定持续时间时不默认添加这一要求。

(待补：统一时限 T 、布料画面覆盖阈值 θ_C 与持续确认窗口 d_C ，不沿用未经核实的历史阈值。)

若最终物体与目标区域均可清晰评价，式(45)的两个谓词可以由同一参考帧判定，不必依赖假设的最终目标遮挡。执行中被机械臂临时遮挡仍可能导致评价证据不足，但不能把这种局部情况混同于任务要求布料最后重新遮住物体。暴露、分离、推动和复原是有助于解释行为的过程

事件；并非所有任务都必须采用同一组过程标签，更不要求在问题定义中指定阶段头。

(待补：两个平台的硬件、控制频率、传感器、动作单位、任务实例、数据规模、独立训练种子和评估重复次数。)

训练初始位置集合为

$$\mathcal{P}_{tr} = \{(0, 0), (0, 3), (1, 1), (1, 2), (2, 0), (2, 3)\},$$

测试位置为 $\mathcal{P}_{test} = \{0, 1, 2\} \times \{0, 1, 2, 3\}$ 。三个物体在十二个位置形成每轮 36 个条件单元。应分别报告已采集位置与未采集初始位置上的结果；该设置不代表未见物体类别或任意动力学泛化。

(待补：各方法每个条件的有效试验次数、失败剔除规则、配对顺序和区间估计方法；独立人工或冻结评估器的审核协议。)

各策略使用相同示范数据和基础策略训练轮次作为主要比较条件。额外语义标签、分割预训练以及残差训练的计算开销须单独披露，不将相同基础训练轮次解释为全部资源完全相同。

B. Overall Performance and Generalization

(待补结果：各平台与任务的成功次数/总次数、置信区间、完成时间和失败类型；提供相同条件的配对比较，不使用未核验的近似百分比。)

C. Semantic Inputs and Task-Query Ablations

(待补实验与结果：固定视角和训练预算，对照 RGB、RGB 加语义、等量无监督查询、有监督查询；报告几何误差、查询屏蔽后的动作变化及闭环成功率。)

D. History and Residual Feedback Ablations

(待补实验与结果：同一冻结基础 checkpoint 下比较无残差、MLP、GRU；增加等容量对照、历史置乱或重置和延迟扫描，避免将基础策略差异归因于记忆。)

E. Validation of Analytical Conditions

(待补实验与结果：统一尺度和槽位的动作 MSE/MAE、关键事件分层、语义质量分层、残差对齐项及修正能量；说明离线分布与闭环分布差别。不能通过低训练 loss 宣称覆盖条件已被证明。)

F. Runtime and Failure Analysis

(待补结果：端到端延迟分位数、过期丢弃率、修正覆盖率、推理资源、遮挡与拨空等失败案例；失败视频与分析须能追溯到原始记录。)

VI. Discussion and Conclusion

A. Discussion

语义和几何监督提供任务相关归纳偏置，但不能补全未覆盖的接触动力学，也不能恢复观测中无法识别的任意隐藏状态。质量分数可能无法发现稳定的系统误分，历史模型也可能依赖错误相关性。当前查询监督不等同于显式完成判定，监督残差亦不具备强化学习的策略改进保证。本章分析中的覆盖、近似充分性和局部平滑性是适用条件，不是网络结构自动保证的性质。

(待补讨论：依据最终失败案例说明方法在哪些条件下失效，跨平台和任务迁移的代价，以及自动标注的人工开销。)

B. Conclusion

（待补正文：基于最终验证结果，简洁总结问题、方法、获得支持的结论及剩余局限；暂不声明统计显著提升或通用收敛。）

参考文献

- [1] G. E. Fainekos and G. J. Pappas, “Robustness of temporal logic specifications for continuous-time signals,” *Theoretical Computer Science*, vol. 410, pp. 4262–4291, 2009. [Online]. Available: <https://www.georgejpappas.org/wp-content/uploads/2024/04/TCS-FP09.pdf>
- [2] J. Schulman, S. Levine, P. Moritz, M. I. Jordan, and P. Abbeel, “Trust region policy optimization,” in *Proceedings of ICML*, ser. PMLR, vol. 37, 2015, pp. 1889–1897. [Online]. Available: <https://proceedings.mlr.press/v37/schulman15.html>
- [3] S. Ross, G. Gordon, and J. A. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *Proceedings of AISTATS*, ser. PMLR, vol. 15, 2011, pp. 627–635. [Online]. Available: <https://proceedings.mlr.press/v15/ross11a.html>
- [4] S. Tu, A. Robey, T. Zhang, and N. Matni, “On the sample complexity of stability constrained imitation learning,” in *Proceedings of LADC*, ser. PMLR, vol. 168, 2022, pp. 180–191. [Online]. Available: <https://proceedings.mlr.press/v168/tu22a.html>
- [5] P. de Haan, D. Jayaraman, and S. Levine, “Causal confusion in imitation learning,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019. [Online]. Available: <https://arxiv.org/abs/1905.11979>
- [6] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” in *Robotics: Science and Systems*, 2023. [Online]. Available: <https://arxiv.org/abs/2304.13705>
- [7] N. Ravi *et al.*, “SAM 2: Segment anything in images and videos,” arXiv:2408.00714, 2024. [Online]. Available: <https://arxiv.org/abs/2408.00714>